Universidad Europea MADRID

TRABAJO FIN DE MÁSTER

Máster Universitario en Bioinformática

Versión Memoria Académica

AGENTE ANALÍTICO OMOP

APLICACIÓN DE IA CONVERSACIONAL PARA DEMOCRATIZAR EL ANÁLISIS DE DATOS DE BASES DE DATOS CLÍNICAS OMOP CDM 5.4

Autor: Sergio Bermúdez Sánchez

Tutor: Isidoro Gutiérrez Álvarez

Villaviciosa de Odón, *octubre de 2026*

Resumen....3
1. Introducción....4
1.1. Contexto y formulación del problema....4
1.2. El modelo común de datos OMOP CDM y el ecosistema OHDSI....4
1.3. Inteligencia Artificial Conversacional y Text-to-SQL en biomedicina....6
2. Hipótesis y Objetivos....7
2.1. Hipótesis....7
2.2. Objetivos....7
2.2.1. Objetivo general....7
2.2.2. Objetivos específicos....7
2.3. Alineación con los Objetivos de Desarrollo Sostenible (ODS)....8
3. Materiales y Métodos....8
3.1. Arquitectura funcional multi-agente....8
3.2. Infraestructura técnica y persistencia de datos....10
3.3. Metodología de evaluación....10
3.3.1. Conjunto de datos de referencia (Gold Standard)....10
3.3.2. Métricas e índices de evaluación....11
3.3.3. Protocolo de ejecución y análisis estadístico....11
4. Resultados....12
4.1. Evaluación cualitativa....12
4.2. Evaluación cuantitativa global....13
4.3. Desempeño según nivel de complejidad....14
4.4. Rendimiento por dominio del modelo OMOP CDM....15
4.5. Dinámica de resolución y beneficio del refinamiento interactivo....17
5. Discusión....20
5.1. Interpretación de los hallazgos....20
5.2. Directrices de optimización en ingeniería de prompts....21
5.3. Limitaciones del estudio....21
6. Conclusiones y Trabajo Futuro....22
6.1. Conclusiones....22
6.2. Trabajo futuro....22
7. Bibliografía....24
8. Anexos....24

Resumen

El acceso analítico a datos observacionales de salud estandarizados bajo el modelo de datos común OMOP CDM (Observational Medical Outcomes Partnership Common Data Model) se encuentra condicionado por la necesidad de competencias técnicas avanzadas en lenguaje SQL y el conocimiento exhaustivo de las ontologías y jerarquías de OHDSI. Con el fin de mitigar esta barrera de adopción en entornos asistenciales y de investigación, en el presente Trabajo Fin de Máster se diseñó e implementó el **Agente Analítico OMOP**, una prueba de concepto fundamentada en arquitecturas de agentes conversacionales e inteligencia artificial generativa, orientada a la resolución de consultas de caracterización e incidencia clínica formuladas en lenguaje natural.

La solución se estructuró a partir de un sistema multi-agente modular desarrollado sobre el framework Google ADK (Agent Development Kit), orquestando modelos fundacionales Gemini-2.5-Flash junto con un mecanismo de Generación Aumentada por Recuperación (RAG) especializado en la resolución terminológica hacia vocabularios estandarizados (SNOMED CT y RxNorm). El sistema desacopla funcionalmente las tareas de extracción ontológica, validación de identificadores canónicos (concept_id), construcción de sintaxis relacional y verificación semántico-estructural contra el esquema relacional OMOP 5.4.

La evaluación experimental se llevó a cabo sobre una batería estandarizada (Gold Standard) de N=201 consultas clínicas extraídas y adaptadas de la QueryLibrary de OHDSI, estratificadas por dominio y complejidad computacional. Los resultados evidencian una Validez Sintáctica y Estructural inicial (zero-shot) del 23,9%, la cual converge progresivamente hasta una media consolidada del 84,9% (0,271) mediante un protocolo de refinamiento iterativo de hasta tres turnos. Por su parte, la Precisión Terminológica de Vocabulario alcanzó un promedio global del 92,5% (0,239), con un 90,0% de asignaciones óptimas. Estos hallazgos confirman la viabilidad técnica y operativa de los sistemas multi-agente como interfaz para democratizar el análisis observacional biomédico, delimitando a su vez las necesidades de ingeniería de prompts y control de esquemas ante consultas relacionales complejas.

Palabras clave: OMOP CDM, OHDSI, Inteligencia Artificial Conversacional, Sistemas Multi-Agente, Text-to-SQL, Vocabularios Controlados, RAG, Bioinformática Clínica.

---

1. Introducción

1.1. Contexto y formulación del problema

La explotación analítica directa de registros médicos electrónicos (RME) y bases de datos observacionales representa un desafío recurrente para clínicos e investigadores biomédicos no familiarizados con arquitecturas de almacenamiento relacional. Con frecuencia, preguntas epidemiológicas y asistenciales de alto valor —tales como la proporción de pacientes con fibrilación auricular que reciben anticoagulaterapia oral, o la tasa de incidencia estratificada de neumonía en cohortes geriátricas— demandan una intermediación constante.

En los ecosistemas hospitalarios y centros de investigación actuales, la resolución de este tipo de interrogantes suele canalizarse a través de tres vías principales:

1. **Herramientas de Inteligencia de Negocio (BI) y plataformas analíticas cerradas:** Interfaces preconfiguradas (e.g., OHDSI Atlas, Power BI, Tableau) que, si bien son robustas, a menudo carecen de la flexibilidad requerida para interrogaciones exploratorias ad-hoc no contempladas en los paneles predefinidos.
2. **Dependencia de unidades de soporte bioinformático:** Solicitud formal de extracciones a equipos técnicos especializados, un proceso que suele introducir latencias operativas y sobrecarga en los grupos de análisis.
3. **Interacción técnica directa mediante lenguajes declarativos (SQL):** Enfoque restringido a usuarios que dominan la sintaxis SQL, la normalización de esquemas clínicos y las directrices de anonimización y protección de datos personales (RGPD/PII).

Esta estratificación técnica genera una asimetría en la explotación del dato biomédico, impidiendo que el personal asistencial acceda de forma ágil a la evidencia derivada de la práctica clínica real.

1.2. El modelo común de datos OMOP CDM y el ecosistema OHDSI

El Consorcio para las Ciencias de la Salud y la Informática de Datos Observacionales (*Observational Health Data Sciences and Informatics*, OHDSI) mantiene el *Observational Medical Outcomes Partnership Common Data Model* (OMOP CDM) (Hripcsak et al., 2015; OHDSI Collaborative, 2021). Este estándar abierto homogeneiza la estructura, formato y terminología de fuentes clínicas heterogéneas, permitiendo el despliegue de estudios multicéntricos y reproducibles a nivel internacional.

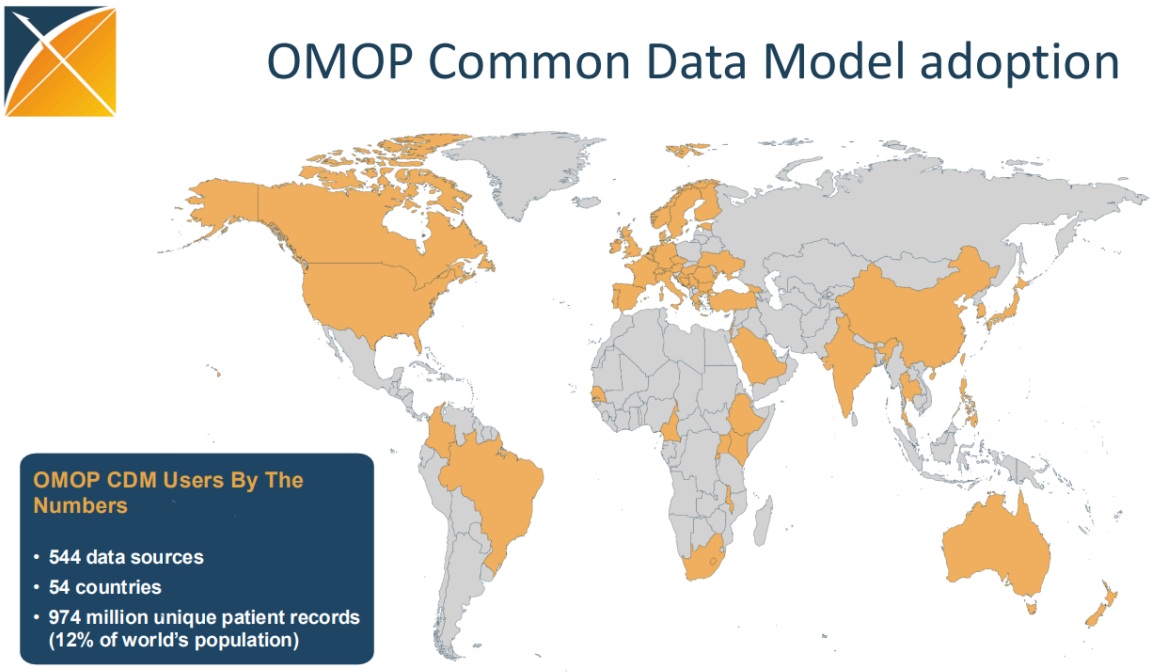


Figura 1. Tomado de *State of the OHDSI community* (p. 16), por G. Hripcsak, 2025, Observational Health Data Sciences and Informatics (https://www.ohdsi.org/wp-content/uploads/2025/10/OHDSI2025-Hripcsak-State-of-Community.pdf).

Bajo este modelo, la información clínica no solo se organiza en tablas relacionales uniformes (tales como condition_occurrence, drug_exposure o measurement), sino que descansa sobre un repositorio ontológico estandarizado. Dicho sistema traduce códigos locales y clasificaciones heterogéneas —como la Clasificación Internacional de Enfermedades (World Health Organization, 2018) o la ICPC— a conceptos normalizados y unívocos procedentes de terminologías clínicas estandarizadas como SNOMED CT (SNOMED International, 2024), RxNorm o LOINC, identificados numéricamente mediante concept_id.

Pese a sus notables ventajas, la complejidad inherente al diseño entidad-relación y las reglas de validez temporal y ontológica del modelo OMOP imponen una curva de aprendizaje pronunciada para los usuarios no bioinformáticos (OHDSI, 2024a).

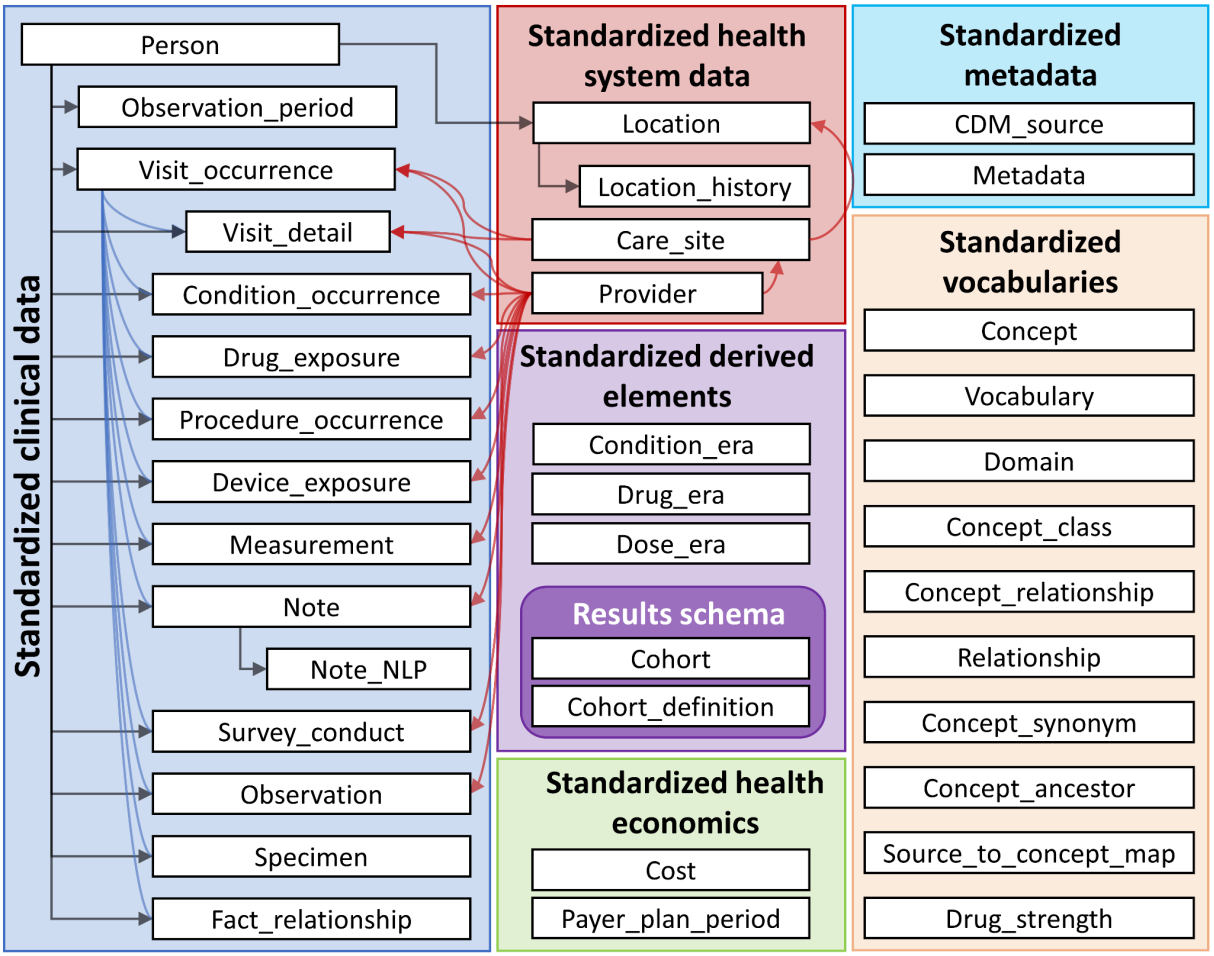


Figura 2. Nota. Adaptado de Data standardization: OMOP Common Data Model, por Observational Health Data Sciences and Informatics (OHDSI), n.d. (https://www.ohdsi.org/data-standardization/).

1.3. Inteligencia Artificial Conversacional y Text-to-SQL en biomedicina

La convergencia entre los Modelos de Lenguaje de Gran Escala (*Large Language Models*, LLMs) y el procesamiento del lenguaje natural (PLN) ha impulsado el paradigma del Análisis Conversacional (*Conversational Analytics*). Esta disciplina persigue la formulación de consultas analíticas sobre almacenes de datos utilizando lenguaje natural, traduciendo directivas semánticas en instrucciones SQL ejecutables (*Text-to-SQL*).

No obstante, la transposición de *Text-to-SQL* al dominio biomédico plantea retos singulares:

- **Dispersión y polisemia ontológica:** La necesidad de mapear expresiones clínicas ambiguas hacia identificadores estándar específicos sin incurrir en alucinaciones terminológicas.
- **Topología relacional compleja:** La necesidad de enlazar tablas de eventos con jerarquías taxonómicas (concept_ancestor) y tablas agregadas de persistencia temporal (condition_era, drug_era).

Para abordar estas dificultades de manera estructurada, se concibió la prueba de concepto del **Agente Analítico OMOP**, un sistema multi-agente enfocado en procesar preguntas de caracterización poblacional e incidencia epidemiológica mediante un flujo modular y verificable.

---

2. Hipótesis y Objetivos

2.1. Hipótesis

La implementación de una arquitectura multi-agente basada en Modelos de Lenguaje de Gran Escala, combinada con un motor de Generación Aumentada por Recuperación (RAG) especializado en vocabularios OHDSI y un mecanismo de validación sintáctica en bucle, permite traducir preguntas formuladas en lenguaje natural a sentencias SQL conformes al estándar OMOP CDM 5.4, alcanzando una validez sintáctico-estructural superior al 80% y superando las barreras técnicas de consulta para usuarios sin formación en programación de bases de datos.

2.2. Objetivos

2.2.1. Objetivo general

Diseñar, implementar y evaluar un sistema de inteligencia artificial conversacional capaz de interpretar consultas analíticas clínicas formuladas en lenguaje natural y generar sentencias SQL reproducibles, semánticamente correctas y ejecutables sobre bases de datos estructuradas conforme a OMOP CDM 5.4.

2.2.2. Objetivos específicos

1. **Modelado y contextualización de metadatos OMOP:** Adaptar el esquema relacional y las restricciones de integridad del estándar OMOP 5.4 en representaciones semánticas interpretables por agentes de IA.
2. **Integración de motores terminológicos con soporte RAG:** Implementar un subagente de búsqueda y validación ontológica acoplado a bases de datos vectoriales y relacionales para mapear términos en lenguaje natural a códigos canónicos (concept_id).

3. **Construcción y orquestación multi-agente de consultas relacionales:** Diseñar un flujo de trabajo desacoplado para la generación, corrección sintáctica iterativa y verificación de consultas SQL contra motores analíticos reales.
4. **Validación experimental comparada:** Evaluar cuantitativa y cualitativamente el desempeño de la arquitectura mediante un conjunto de pruebas estandarizadas (*Gold Standard*) de 201 consultas clínicas, midiendo métricas de precisión terminológica, validez sintáctica y esfuerzo conversacional.

2.3. Alineación con los Objetivos de Desarrollo Sostenible (ODS)

- **ODS 3 (Salud y bienestar):** Facilita la generación ágil de evidencia clínica a partir de datos secundarios, respaldando la investigación epidemiológica y la toma de decisiones basada en datos.
- **ODS 4 (Educación de calidad):** Contribuye a la alfabetización digital y la familiarización del personal médico con la estructura formal de los datos clínicos y las ontologías biomédicas.
- **ODS 9 (Industria, innovación e infraestructura):** Fomenta la adopción de tecnologías abiertas y avanzadas de inteligencia artificial en infraestructuras analíticas sanitarias.
- **ODS 10 (Reducción de las desigualdades):** Disminuye la brecha operativa entre grandes consorcios con amplios equipos bioinformáticos y centros asistenciales con recursos técnicos limitados.

---

3. Materiales y Métodos

3.1. Arquitectura funcional multi-agente

La solución se diseñó siguiendo una arquitectura multi-agente jerárquica con separación estricta de responsabilidades, implementada sobre el entorno Google Cloud Platform utilizando el *Agent Development Kit* (ADK) (Google, 2024) y el modelo fundacional Gemini-2.5-Flash, cuyo flujo de interacción coordinada entre el usuario y los subagentes se detalla en la Figura 3.

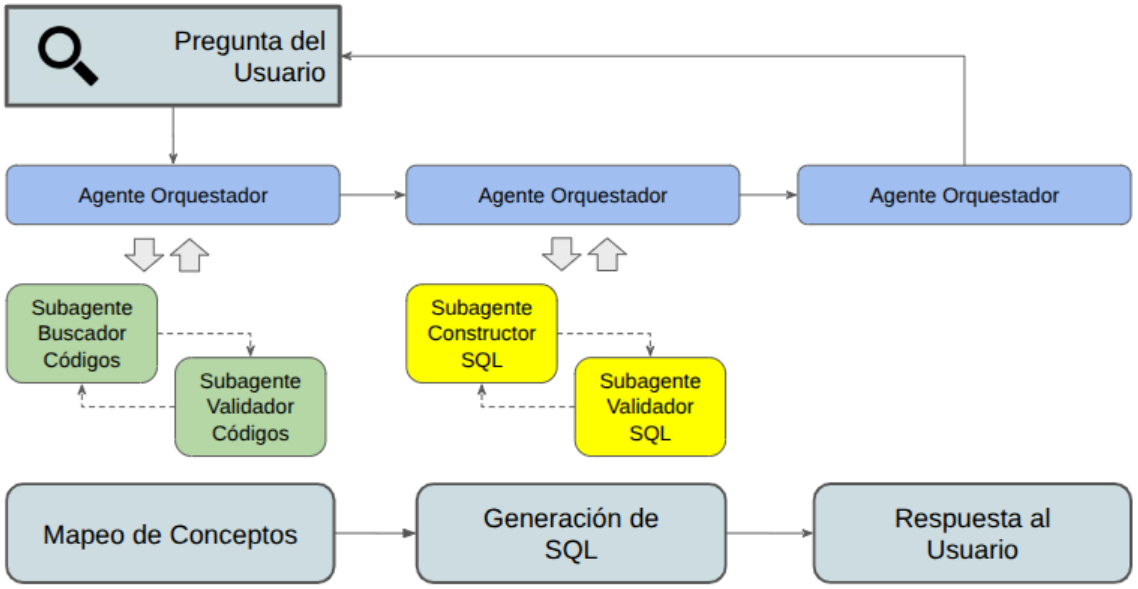


Figura 3. Flujo de interacciones entre los agentes y el usuario

1. **Agente OMOP Orquestador:** Actúa como interfaz central de comunicación y coordinador del flujo de tareas. Descompone la consulta recibida, deriva subtareas analíticas a los agentes operativos y consolida la sentencia SQL final, acompañándola de una explicación didáctica estructurada.
2. **Subagente SNOMED Buscador:** Especializado en el procesamiento lingüístico de las entidades nosológicas y terapéuticas. Emplea un sistema RAG sobre Google Cloud Vertex AI Search para indexar y consultar vocabularios clínicos estandarizados, recuperando los identificadores canónicos (concept_id) correspondientes.
3. **Subagente SNOMED Validador:** Mecanismo de control determinista concebido para verificar que los concept_id recuperados existan en el catálogo y evitar alucinaciones generativas del modelo fundacional.
4. **Subagente OMOP SQL Constructor:** Transforma la intención clínica y los identificadores validados en una consulta formal SQL compatible con el estándar OMOP CDM 5.4.
5. **Subagente SQL Validador:** Ejecuta la sintaxis propuesta contra un entorno controlado en Google Cloud BigQuery. Detecta errores sintácticos, inconsistencias relacionales o tipológicas, retroalimentando en tiempo real al Constructor para su reformulación si la consulta no es válida.

3.2. Infraestructura técnica y persistencia de datos

La infraestructura de soporte y la capa de almacenamiento relacional e indexación vectorial se implementaron de forma nativa sobre el ecosistema de Google Cloud Platform (Figura 4), estructurándose en dos componentes principales:

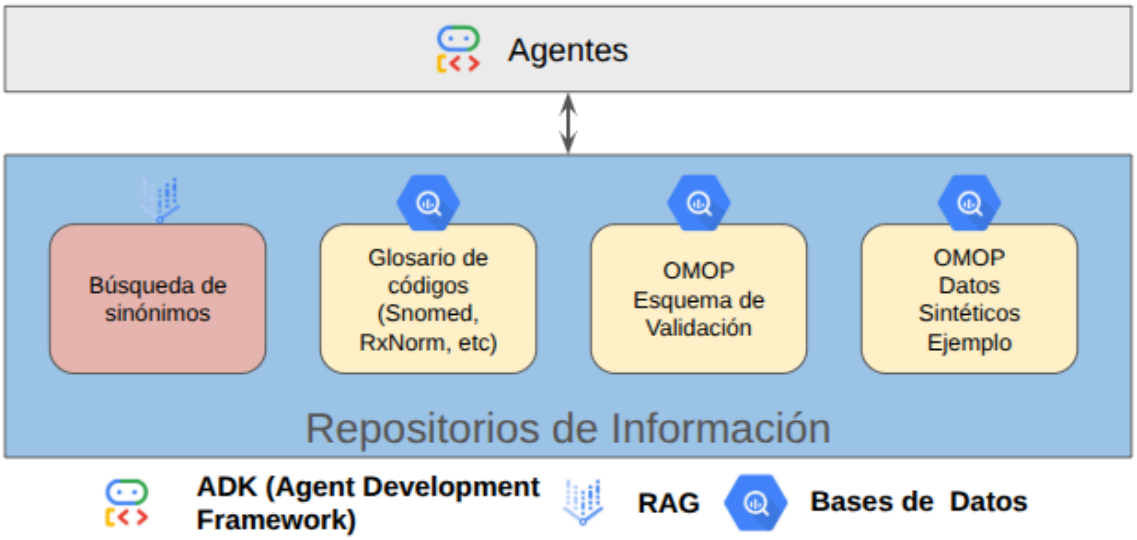


Figura 4. Arquitectura técnica

- **Capa de cómputo y despliegue:** La solución se empaquetó en contenedores Docker y se desplegó en Google Cloud Run a través de canalizaciones de Cloud Build.
- **Capa de persistencia:** Aloja tres conjuntos de datos en Google Cloud BigQuery:
    - *Repositorio Terminológico:* Tablas ontológicas normalizadas del ecosistema OHDSI (concept, concept_ancestor, concept_relationship, vocabulary).
    - *Esquema de Validación:* Catálogo con la estructura de metadatos, llaves primarias/foráneas y restricciones del modelo OMOP 5.4.
    - *Base de Datos Sintética:* Esquema con pacientes simulados sintéticamente para certificar la ejecutabilidad analítica y volumétrica de las consultas.

3.3. Metodología de evaluación

El marco de evaluación experimental se dividió en una demostración cualitativa de trazabilidad y un análisis cuantitativo sistemático mediante el marco automatizado tfm-eval.

3.3.1. Conjunto de datos de referencia (*Gold Standard*)

Se confeccionó una cohorte experimental de $N = 201$ consultas clínicas en español a partir de las plantillas analíticas de la *QueryLibrary* de OHDSI. Cada caso de prueba incluyó:

- Enunciado en lenguaje natural.
- Sentencia SQL canónica de referencia optimizada para BigQuery.
- Conjunto de concept_id esperados.
- Clasificación por dominio funcional (concept, condition_occurrence, drug_exposure, condition_era, entre otros).
- Nivel de complejidad estructural:
    - **Baja ($N = 26$):** Consultas directas sobre una sola tabla o uniones elementales con diccionarios.
    - **Intermedia ($N = 71$):** Consultas con múltiples cláusulas JOIN, agrupaciones analíticas o subconsultas no correlacionadas.
    - **Compleja ($N = 104$):** Consultas estructuradas con Expresiones de Tablas Comunes (CTEs), jerarquías de ancestros recursivas, particiones analíticas o funciones de ventana.

3.3.2. Métricas e índices de evaluación

1. **Validez Sintáctica y Estructural (VSE):** Métrica normalizada $[0, 1]$ calculada a partir de dos componentes:

$$VSE = w_1 \cdot C_{ejecutabilidad} + w_2 \cdot C_{similitud}$$

Donde $C_{ejecutabilidad} \in \{0, 0{,}10\}$ evalúa si la sentencia se ejecuta con éxito en el gestor BigQuery sin arrojar errores de compilación ni de ejecución; y $C_{similitud} \in [0, 0{,}90]$ cuantifica la correspondencia estructural (cláusulas, tablas enlazadas y proyecciones) respecto al *Gold Standard*.

2. **Precisión Terminológica del Vocabulario (PTV):** Proporción de conceptos clínicos correctamente identificados frente a los identificadores de referencia:

$$PTV = |C_{generados} \cap C_{referencia}| / |C_{referencia}|$$

3. **Esfuerzo Conversacional:** Número de turnos interactivos (de 1 a 3) requeridos para lograr la resolución satisfactoria de la consulta (definida operativamente como VSE ≥ 0,80).

3.3.3. Protocolo de ejecución y análisis estadístico

La interacción conversacional se ejecutó mediante un protocolo iterativo secuencial:

- **Turno 1 (*Zero-Shot*):** Introducción de la pregunta médica sin indicaciones contextuales adicionales.
- **Turno 2 (Refinamiento semántico):** Si la consulta no alcanza el umbral de resolución, el sistema inyecta la confirmación explícita de los dominios involucrados (domain_main, domain_others).
- **Turno 3 (Concreción declarativa):** Si persiste el fallo, se fuerza una instrucción de emisión directa requiriendo la sentencia SELECT final aislada.

Las comparaciones entre grupos de complejidad y dominios se contrastaron mediante pruebas no paramétricas (Kruskal-Wallis, Mann-Whitney y Wilcoxon para muestras pareadas), fijando el nivel de significación en $\alpha = 0,05$.

---

4. Resultados

4.1. Evaluación cualitativa

El comportamiento interactivo evidenció la capacidad del agente para mantener la coherencia ontológica y la trazabilidad técnica en consultas clínicas estructuradas.

```
None
[Usuario]
  "Genera una consulta SQL para visualizar el número acumulado de pacientes con
diabetes mellitus agrupados por año."

[Agente OMOP - Turno 1]
  1. Identificación terminológica:
     - Concepto canónico: 201820 | Diabetes mellitus | SNOMED | Standard: S
  2. Generación SQL (BigQuery):
     SELECT
       EXTRACT(YEAR FROM condition_start_date) AS anio_diagnostico,
       COUNT(DISTINCT person_id) AS total_pacientes
     FROM `bio-med-480108.omop_54_a.condition_occurrence`
     WHERE condition_concept_id = 201820
     GROUP BY anio_diagnostico
```

```
    ORDER BY anio_diagnostico ASC;
  3. Desglose explicativo:
    - Filtro por condición estándar única (201820).
    - Agrupación por año calendario y agregación unívoca de person_id.

[Usuario - Turno 2]
  "Modifica la consulta anterior para incluir todas las formas y subtipos
descendientes de la patología."

[Agente OMOP - Turno 2]
  1. Reformulación con expansión taxonómica:
    SELECT
      EXTRACT(YEAR FROM co.condition_start_date) AS anio_diagnostico,
      COUNT(DISTINCT co.person_id) AS total_pacientes
    FROM `bio-med-480108.omop_54_a.condition_occurrence` co
    JOIN `bio-med-480108.omop_54_a.concept_ancestor` ca
      ON co.condition_concept_id = ca.descendant_concept_id
    WHERE ca.ancestor_concept_id = 201820
    GROUP BY anio_diagnostico
    ORDER BY anio_diagnostico ASC;
  2. Validación: Ejecutable sin errores en BigQuery (Tiempo: 412 ms).
```

4.2. Evaluación cuantitativa global

El análisis sobre la muestra completa ($N = 201$) demostró una alta efectividad del sistema, alcanzando un promedio final de Validez Sintáctica y Estructural de $0,849$ ($\pm$ $0,271$) y una mediana de $0,950$ [IQR: $0,130$]. La Precisión Terminológica de Vocabulario se situó en $0,925$ ($\pm$ $0,239$), demandando un promedio de $2,100$ turnos conversacionales ($\pm$ $0,755$).

Tabla 1.

Estadísticos Descriptivos Globales del Desempeño del Agente (N = 201).

Métrica Evaluada	N	Media +/- DE	Mediana [IQR]	Mín - Máx	IC 95% Media
Validez Sintáctica y Estructural (Final)	201	0.849 +/- 0.271	0.950 [0.130]	0.00 - 1.00	[0.811 - 0.887]
Criterio 1.1: Ejecutabilidad SQL (Max. 0.10)	201	0.094 +/- 0.025	0.100 [0.000]	0.00 - 0.10	[0.090 - 0.097]

Métrica Evaluada	N	Media +/- DE	Mediana [IQR]	Mín - Máx	IC 95% Media
Criterio 1.2: Similitud Estructural Gold Standard (Max. 0.90)	201	0.756 +/- 0.251	0.850 [0.130]	0.00 - 0.90	[0.721 - 0.790]
Precisión Terminológica Vocabulario (Final)	201	0.925 +/- 0.239	1.000 [0.000]	0.00 - 1.00	[0.892 - 0.958]
Turnos Conversacionales Ejecutados	201	2.100 +/- 0.755	2.000 [1.000]	1.00 - 3.00	[1.994 - 2.205]

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

4.3. Desempeño según nivel de complejidad

La estratificación por nivel de dificultad computacional evidenció una marcada estabilidad en niveles bajos e intermedios, frente a una degradación en consultas de alta complejidad.

Tabla 2.

Rendimiento Comparativo por Nivel de Complejidad

Nivel de Complejidad	N (% total)	Validez Sintáctica Media (+/- DE)	Validez Mediana [IQR]	Vocabulario Medio (+/- DE)	Tasa Resolución (Validez > 0.80)	Precisión Vocabulario Perfecta (= 1.00)
Baja	26 (12.9%)	0.928 +/- 0.146	0.980 [0.040]	1.000 +/- 0.000	92.3% (24/26)	100.0% (26/26)
Intermedia	71 (35.3%)	0.932 +/- 0.167	0.980 [0.040]	0.967 +/- 0.139	95.8% (68/71)	94.4% (67/71)
Compleja	104 (51.7%)	0.773 +/- 0.326	0.950 [0.242]	0.877 +/- 0.304	69.2% (72/104)	84.6% (88/104)

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

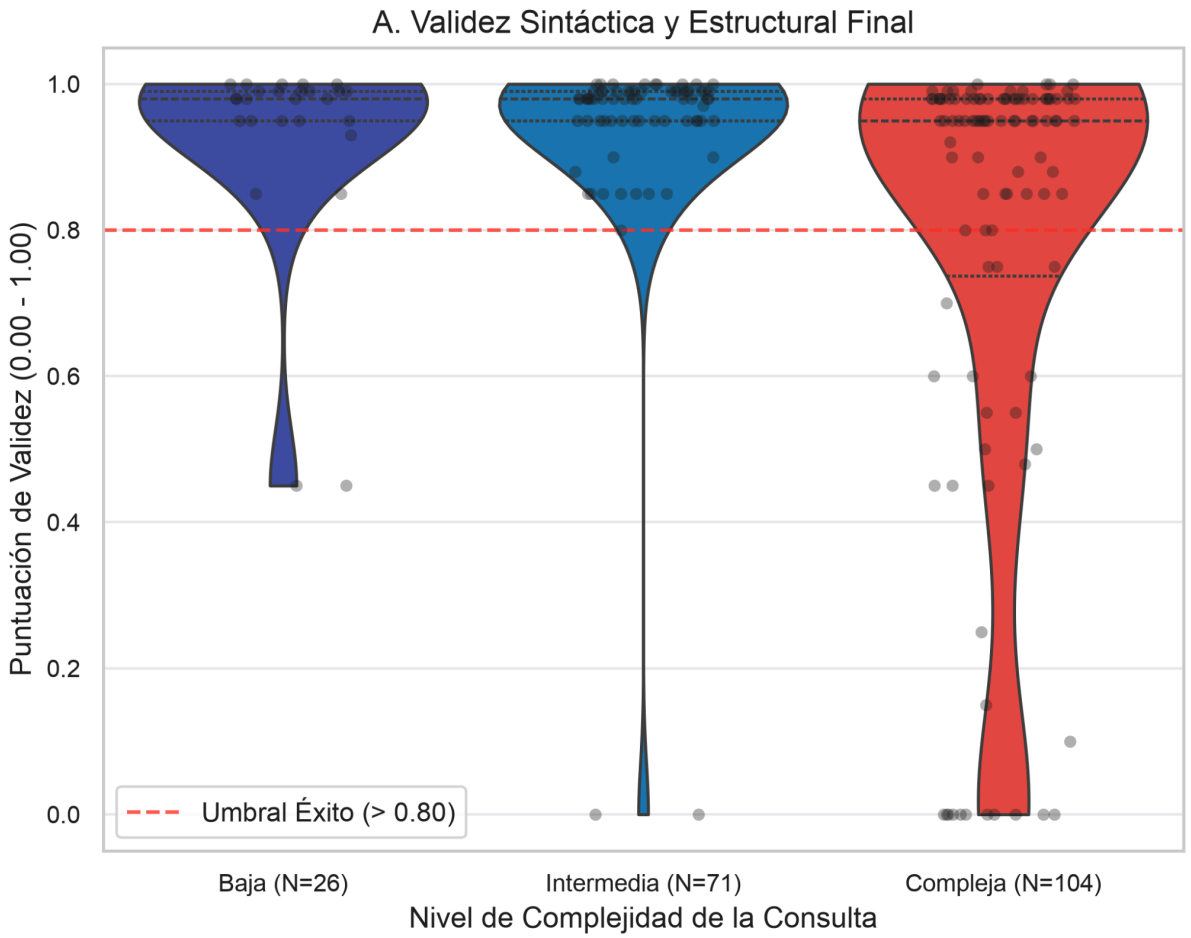


Figura 5. Distribución del Rendimiento del Agente OMOP por Nivel de Complejidad. Panel A: Puntuación de Validez Sintáctica y Estructural Final. Las líneas discontinuas representan los umbrales de éxito operativo (0.80) y asignación perfecta (1.00).

El contraste de Kruskal-Wallis confirmó diferencias significativas entre niveles tanto para la Validez Sintáctica ($H = 23,61$; $p < 0,001$) como para la Precisión Terminológica ($H = 8,12$; $p = 0,017$). El análisis *post-hoc* demostró que no existen discrepancias entre complejidad baja e intermedia ($Z = 0,28$; p_{adj} = 0,782), mientras que las consultas complejas experimentaron un descenso significativo respecto a la intermedia ($Z = 4,34$; p_{adj} < 0,001) y a la baja ($Z = 3,33$; p_{adj} = 0,002), tal como refleja la dispersión de puntuaciones ilustrada en la Figura 5.

4.4. Rendimiento por dominio del modelo OMOP CDM

El análisis por tabla relacional primaria reflejó variaciones sensibles asociadas a la naturaleza de los registros.

Tabla 3. *Desempeño estratificado por dominio principal OMOP CDM 5.4.*

Tabla 3.

Rendimiento del Agente Desglosado por Dominio Principal OMOP

Dominio Principal OMOP	N (% total)	Validez Sintáctica Media (+/- DE)	Validez Mediana	Precisión Vocabulario Media	Turnos Medios	Tasa Éxito (> 0.80)
concept	51 (25.4%)	0.879 +/- 0.194	0.950	0.975	2.140	0.824
drug_exposure	43 (21.4%)	0.798 +/- 0.355	0.980	0.956	2.230	0.791
condition_era	26 (12.9%)	0.662 +/- 0.387	0.850	0.795	2.580	0.577
condition_occurrence	23 (11.4%)	0.945 +/- 0.058	0.980	0.830	1.570	0.957
drug_era	20 (10.0%)	0.821 +/- 0.303	0.980	0.866	2.600	0.700
observation_period	20 (10.0%)	0.931 +/- 0.113	0.980	1.000	1.650	0.950
person	9 (4.5%)	0.984 +/- 0.005	0.980	1.000	1.220	1.000
cost	3 (1.5%)	0.947 +/- 0.045	0.950	1.000	2.330	1.000
care_site	2 (1.0%)	0.975 +/- 0.035	0.975	1.000	1.000	1.000
payer_plan_period	2 (1.0%)	0.970 +/- 0.028	0.970	1.000	1.500	1.000
vocabulary	2 (1.0%)	0.965 +/- 0.021	0.965	1.000	3.000	1.000

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

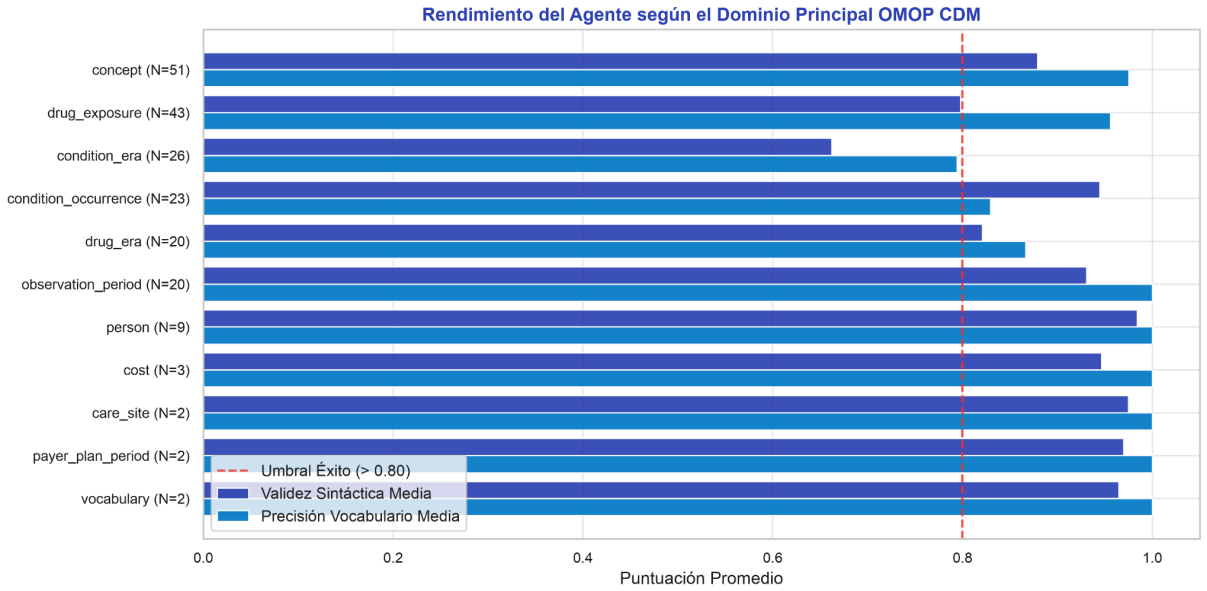


Figura 6. Rendimiento Promedio del Agente según el Dominio Principal OMOP CDM. Comparación entre Validez Sintáctica Media y Precisión Terminológica de Vocabulario frente al umbral de corte del 80%.

Las diferencias entre dominios fueron estadísticamente significativas ($H = 15,65$; $p = 0,016$). Mientras que los dominios de entidades directas (person, condition_occurrence, observation_period) alcanzaron tasas de éxito ≥ 95%, las tablas agregadas de persistencia clínica representaron el mayor desafío. La comparación directa entre la tabla de eventos puntuales (condition_occurrence) y su correspondiente derivada temporal (condition_era) reveló una penalización estadísticamente significativa en el agente ($U = 167,0$; $p = 0,0078$) (Figura 6).

4.5. Dinámica de resolución y beneficio del refinamiento interactivo

La distribución de los turnos conversacionales requeridos exhibió una fuerte dependencia de la complejidad de la consulta ($\chi^2 = 23,11$; $p = 0,0001$) (Figura 7). En el nivel bajo, el 46,2% de los problemas se resolvió en el primer turno (*zero-shot*); por el contrario, en el estrato complejo, solo el 15,4% alcanzó resolución inmediata, precisando un 46,2% el agotamiento de los tres turnos de diálogo.

Tabla 4.

Tabla de Contingencia: Nivel de Complejidad x Turnos Conversacionales Ejecutados

Nivel de Complejidad (N, % Fila)	Turno 1	Turno 2	Turno 3	Total
Baja	12 (46.2%)	7 (26.9%)	7 (26.9%)	26 (100.0%)

Nivel de Complejidad (N, % Fila)	Turno 1	Turno 2	Turno 3	Total
Intermedia	20 (28.2%)	38 (53.5%)	13 (18.3%)	71 (100.0%)
Compleja	16 (15.4%)	40 (38.5%)	48 (46.2%)	104 (100.0%)
Total Global	**48 (23.9%)**	**85 (42.3%)**	**68 (33.8%)**	**201 (100.0%)**

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

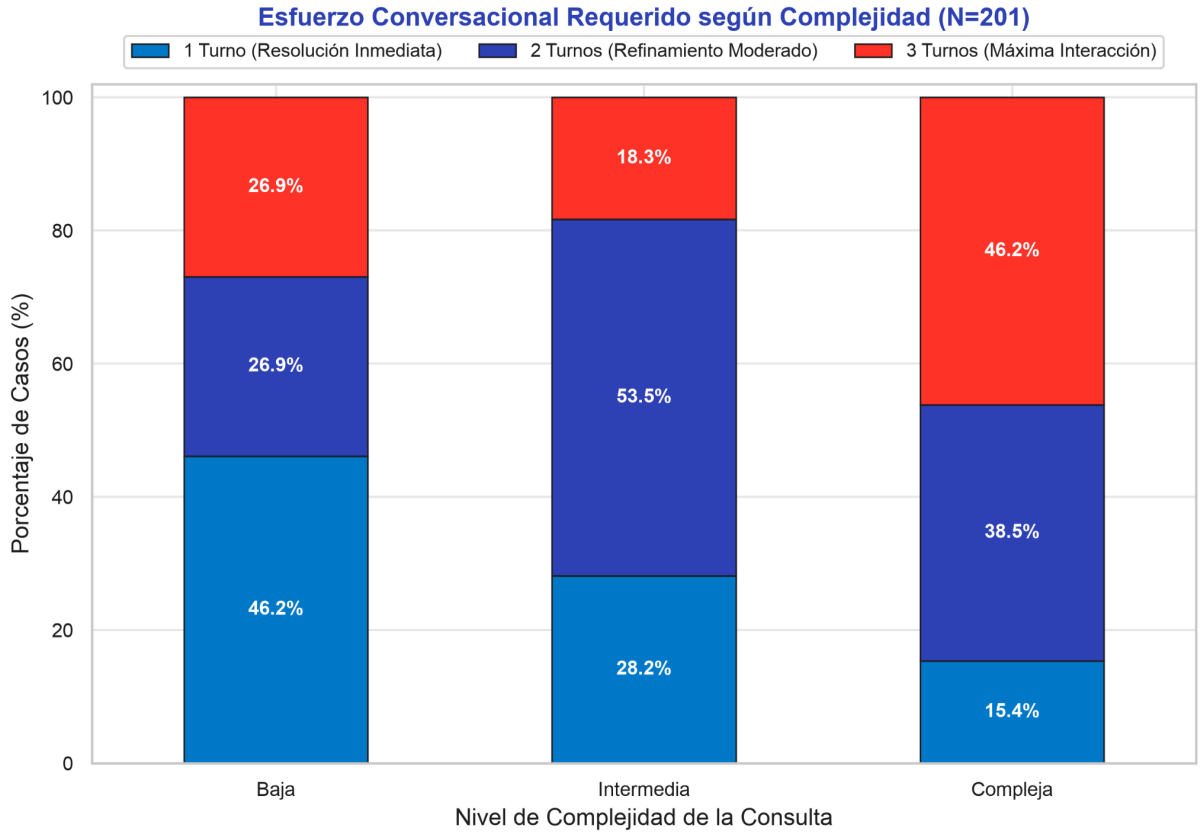


Figura 7. Esfuerzo Conversacional Requerido según la Complejidad de la Consulta (N = 201). Proporción de casos resueltos en Turno 1 (resolución directa), Turno 2 (refinamiento moderado) y Turno 3 (máxima interacción).

La evolución progresiva de las puntuaciones de validez a lo largo de las intervenciones sucesivas describe una trayectoria ascendente constante tanto en media como en mediana (Figura 8).

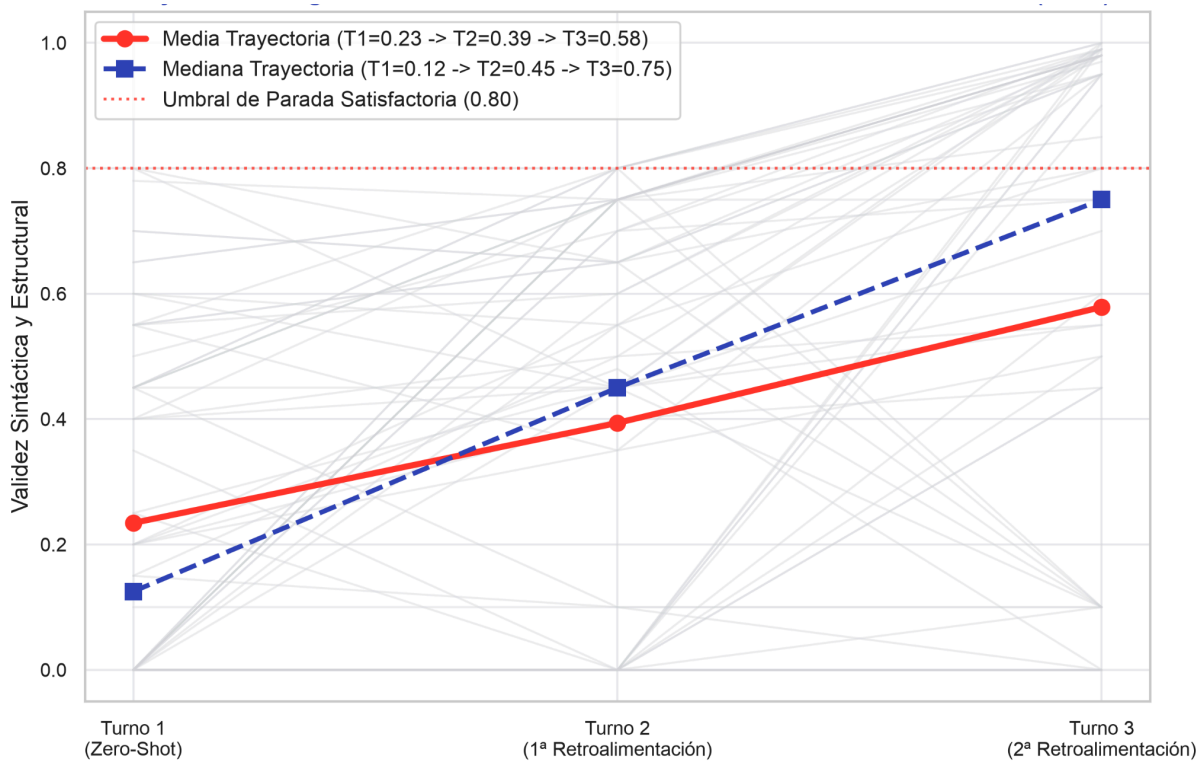


Figura 8.Trayectoria de la mejora de resultados en base a los turnos

El refinamiento conversacional supervisado actuó como mecanismo corrector frente a las ambigüedades iniciales, pasando de un 23,9% de éxito inicial a un 81,6% $(164/201)$ acumulado al tercer turno ($\Delta = + 57,7$ puntos porcentuales; $\chi^2 = 114,01$; $p < 0,001$).

Tabla 5.

Progresión del Desempeño y Ganancia Neta (Delta) por Turno

Transición Evaluada	Cohorte (N)	Validez Inicial	Validez Final	Delta Validez Medio (Mediana)	Casos que Mejoran (N, %)	Prueba de Wilcoxon (W, p)
Turno 1 -> Turno 2	153	0.316 +/- 0.318	0.708 +/- 0.356	+0.392 (+0.350)	118 (77.1%)	W = 264.0 p < 0.001
Turno 2 -> Turno 3	68	0.394 +/- 0.352	0.579 +/- 0.421	+0.185 (+0.195)	45 (66.2%)	W = 247.5 p < 0.001
Turno 1 -> Consolidado Final	**201**	**0.468 +/- 0.369**	**0.849 +/- 0.271**	**+0.381 (+0.340)**	**133 (66.2%)**	**W = 0.0 p < 0.001**

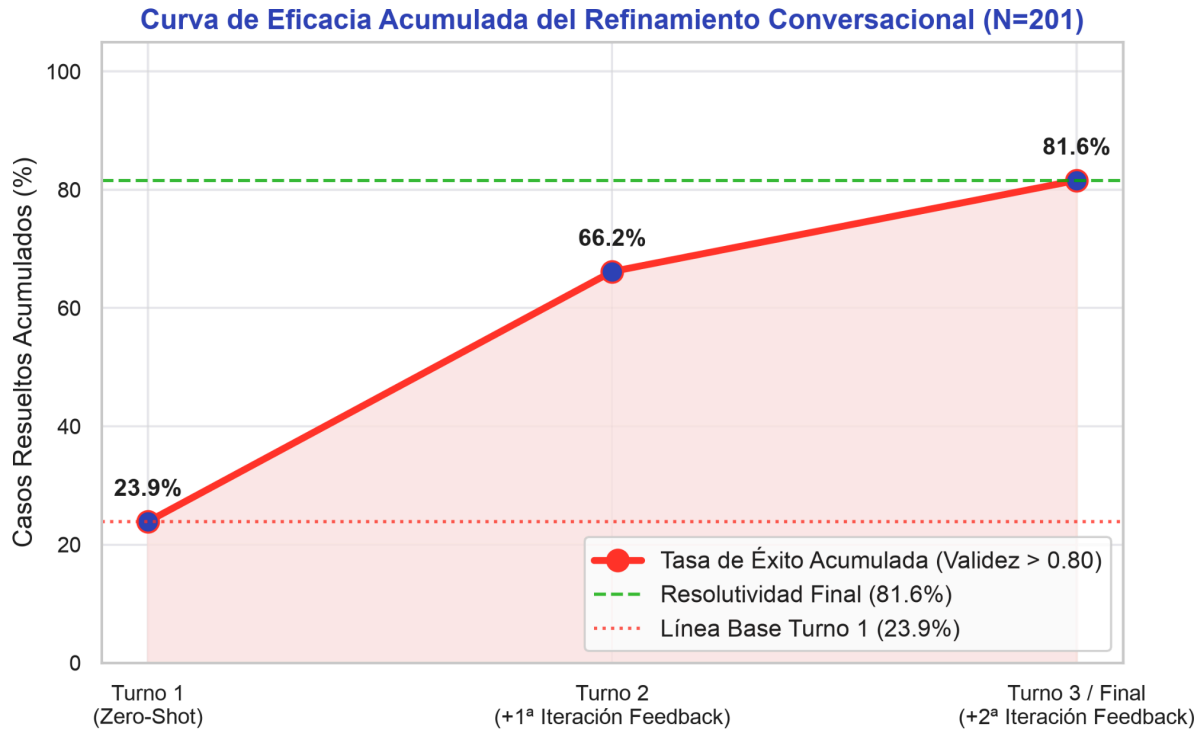


Figura 9. Curva de Eficacia Acumulada del Refinamiento Conversacional (N = 201). Evolución de la resolutividad operativa (Validez > 0.80) desde la respuesta inicial Zero-Shot hasta el tercer turno de interacción.

---

5. Discusión

5.1. Interpretación de los hallazgos

Los resultados confirman que la descomposición modular mediante sistemas multi-agente reduce de forma efectiva la tasa de error estructural en tareas biomédicas de *Text-to-SQL*. El uso de un agente validador determinista frente a un motor relacional real mitiga de manera sustancial la propagación de alucinaciones en el código SQL generado.

Sin embargo, el desfase entre la resolutividad inicial en el Turno 1 (23,9%) y la tasa consolidada (81,6%) pone de manifiesto que el modelo base tiende a simplificar la formulación relacional en ausencia de restricciones explícitas. El análisis de los 37 casos (18,4%) no resueltos tras el Turno 3 evidenció que los fallos no obedecieron a limitaciones del razonamiento lingüístico de Gemini-2.5-Flash, sino a la falta de directrices específicas en el *System Prompt* del subagente constructor respecto a convenciones propias del CDM.

5.2. Directrices de optimización en ingeniería de *prompts*

A partir del análisis de errores, se formalizaron seis directrices prioritarias para su integración en el sistema:

1. **Diferenciación estricta de dominios de persistencia:** Establecer como heurística obligatoria el uso de tablas _era ante términos como "episodio", "persistencia" o "duración", restringiendo las tablas de ocurrencia a eventos puntuales o análisis posológicos.
2. **Inyección automática de expansiones taxonómicas:** Integrar de forma sistemática la tabla concept_ancestor en análisis nosológicos o terapéuticos agregados, previniendo la pérdida de subtipos específicos.
3. **Restricción de integridad en catálogos ontológicos:** Incluir invariantes semánticas explícitas (standard_concept = 'S' y invalid_reason IS NULL) acotadas por domain_id y vocabulary_id.
4. **Homogeneización de agregaciones:** Estandarizar la traducción de recuentos de pacientes mediante COUNT(DISTINCT person_id) y de eventos mediante COUNT(*).
5. **Búsqueda léxica paramétrica:** Preservar la utilización de cláusulas insensibles a mayúsculas (LOWER(), REGEXP_CONTAINS) ante términos exploratorios no canónicos.
6. **Estructuración mediante Expresiones de Tablas Comunes (CTEs):** Exigir la concatenación de bloques lógicos modulares con alias explícitos en consultas de agregación temporal compleja.

Se proyecta que la adopción de estas directivas permitiría elevar la tasa de éxito *zero-shot* por encima del 55%, situando la validez global final en torno al 92-94%.

5.3. Limitaciones del estudio

- **Complejidad terminológica del *Gold Standard*:** La alta precisión del vocabulario (92,5%) se evaluó sobre preguntas redactadas con terminología clínica formal. Es esperable una menor precisión ante entradas que contengan argot hospitalario, abreviaturas no estandarizadas o faltas ortográficas.
- **Heterogeneidad de dialectos SQL:** Aunque la solución se validó en BigQuery, los despliegues reales en consorcios hospitalarios emplean motores variados (PostgreSQL, SQL Server, Oracle, Snowflake), lo que exigirá una capa de adaptación multi-dialecto (e.g., OHDSI SqlRender).

- **Aislamiento del entorno de datos:** En la arquitectura actual, el agente proporciona la consulta SQL para su ejecución posterior por parte del clínico, interrumpiendo el flujo interactivo de visualización directa de los resultados.
- **Gobernanza y protección de datos personales:** El sistema actual no integra una capa de desidentificación de entidades biomédicas nombradas (NER) previa al procesamiento por el LLM, condición sine qua non para el cumplimiento riguroso del RGPD en entornos asistenciales.

---

6. Conclusiones y Trabajo Futuro

6.1. Conclusiones

1. Se demostró la viabilidad técnica y operativa del **Agente Analítico OMOP** como interfaz de lenguaje natural para consultar bases de datos clínicas bajo el estándar OMOP CDM 5.4, alcanzando una validez sintáctica global del 84,9%.
2. La arquitectura multi-agente desacoplada, reforzada con recuperación semántica (RAG) y validación en ejecución, demostró una alta precisión ontológica (92,5%) y garantizó la ejecutabilidad de las sentencias SQL en entornos analíticos reales.
3. El refinamiento conversacional iterativo incrementó la resolución en $+\ 57,7$ puntos porcentuales respecto a la respuesta inicial, demostrando que la interacción guiada es un mecanismo eficaz para corregir ambigüedades semánticas.
4. Las consultas complejas y los dominios de agregación temporal (_era) constituyen el principal cuello de botella computacional, delimitando la necesidad de incorporar heurísticas y reglas de esquema en los *prompts* de orquestación.

6.2. Trabajo futuro

- **Migración a ADK 2.0 y soporte transaccional:** Incorporar patrones de orquestación deterministas que garanticen el paso obligatorio por todas las etapas de validación sintáctica.
- **Traducción multi-dialecto:** Integrar bibliotecas como *SqlRender* para compilar dinámicamente las sentencias a motores relacionales diversos (PostgreSQL, Snowflake, Databricks).
- **Mecanismos de privacidad diferencial y anonimización en el cliente:** Diseñar un subagente de auditoría de privacidad que filtre información de identificación personal (PII) antes de su transmisión a los modelos fundacionales.

- **Interrogación interactiva de datos y generación de informes:** Conectar de forma segura la ejecución de las consultas validadas con módulos automáticos de representación gráfica y cálculo estadístico para el usuario clínico.

---

7. Bibliografía

- Google. (2024). *Agent Development Kit (ADK) documentation*. Google Cloud Developers. https://cloud.google.com/products/agent-development-kit
- Hripcsak, G., Duke, J. D., Shah, N. H., Reich, C. G., Schilling, V. P., Schuemie, M. J., Suchard, M. A., Zorych, I., & Ryan, P. B. (2015). Observational Health Data Sciences and Informatics (OHDSI): Opportunities for observational researchers. *Studies in Health Technology and Informatics*, 216, 574–578.
- Observational Health Data Sciences and Informatics (OHDSI) Collaborative. (2021). *The Book of OHDSI: Observational Health Data Sciences and Informatics*. OHDSI Community. https://ohdsi.github.io/TheBookOfOhdsi/
- Observational Health Data Sciences and Informatics. (2024). *OMOP Common Data Model specification version 5.4*. OHDSI Community. https://ohdsi.github.io/CommonDataModel/cdm54.html
- Observational Health Data Sciences and Informatics. (2024). *QueryLibrary: Predefined queries for OMOP CDM*. GitHub repository. https://github.com/OHDSI/QueryLibrary
- SNOMED International. (2024). *SNOMED CT: Systematized Nomenclature of Medicine -- Clinical Terms*. https://www.snomed.org/
- World Health Organization. (2018). *ICD-11: International Classification of Diseases 11th Revision*. WHO.

---

8. Anexos

- **Repositorio de código fuente:** https://github.com/sogire/tfm-ue-bioinformatica2526-agente-omop
- **Anexo A:** Demostración en vídeo del funcionamiento del Agente Analítico OMOP (Enlace al recurso multimedia).
- **Anexo B:** Especificación formal de *prompts* de sistema para subagentes.
- **Anexo C:** Banco de consultas de referencia (*Gold Standard*, $N = 201$).
- **Anexo D:** Registros tabulares detallados de la evaluación cuantitativa automatizada.

Octubre de 2026. Sergio Bermúdez Sánchez (LinkedIn)