Universidad Europea MADRID

TRABAJO FIN DE MÁSTER

Máster Universitario en Bioinformática

Versión Solución Profesional

AGENTE ANALÍTICO OMOP

APLICACIÓN DE IA CONVERSACIONAL PARA DEMOCRATIZAR EL ANÁLISIS DE DATOS DE BASES DE DATOS CLÍNICAS OMOP CDM 5.4

Autor: Sergio Bermúdez Sánchez

Tutor: Isidoro Gutiérrez Álvarez

Villaviciosa de Odón, *septiembre, 2026*

Resumen **3**
Introducción **4**
¿Qué es el OMOP CDM (OHDSI)? 4
¿Qué son los análisis de IA conversacional? 6
Prueba de concepto: el 'Agente Analítico OMOP' 6
Ejemplo de preguntas a resolver por el 'Agente Analítico OMOP' 7
Hipótesis y objetivos **7**
Hipótesis 7
Objetivos 8
Objetivos específicos 8
Objetivos de desarrollo sostenible (ODS) 8
Materiales y métodos **9**
Esquema funcional y arquitectura técnica del agente **9**
Esquema funcional de agentes y subagentes 10
Arquitectura técnica 12
Acceso al agente OMOP 13
Código 13
Metodología de evaluación de resultados **13**
1. Evaluación cualitativa (Demostración funcional del agente) 13
2. Evaluación cuantitativa 14
Conjunto de datos de evaluación 14
Métricas de Evaluación 15
Procedimiento de evaluación 16
Resultados **18**
Resultados cualitativos 18
Ejemplo 1: Consulta analítica (Diabetes) 18
Ejemplo 2: Mapeo y extracción terminológica (Demencia) 20
Resultados cuantitativos 21
Resultados por nivel de complejidad 21
Resultados por dominio OMOP CDM 23
Resultados por nivel de complejidad y turno de resolución 24
Efecto del Refinamiento Iterativo 26
Discusión **28**
Mejora del Prompt 28
Mejoras a realizar en las instrucciones del agente OMOP 28
Benefício e Impacto Operativo Esperado 29
Limitaciones en la evaluación de la precisión del vocabulario 30
Limitaciones detectadas para un despliegue en producción 30
Conclusiones y potenciales desarrollos a futuro **30**
Conclusiones 30
Potenciales desarrollos a futuro 31
Bibliografía **33**
Anexos **33**

Resumen

El acceso a los datos de salud estandarizados bajo el modelo de datos común **OMOP CDM** sigue limitado por la necesidad de contar con conocimientos técnicos avanzados en SQL y conocer la estructura y jerarquías de los vocabularios OHDSI. Para resolver esta barrera, en este Trabajo Fin de Máster he desarrollado el **Agente Analítico OMOP**, una prueba de concepto basada en IA conversacional que permite a profesionales sanitarios e investigadores formular preguntas analíticas de caracterización e incidencia en lenguaje natural.

La solución se ha implementado mediante una **arquitectura multi-agente** utilizando el **framework ADK** (Agent Development Kit)**.** El modelo utilizado es Gemini-2.5-flash, aunque el sistema es agnóstico y permite su modificación, y se apoya por un sistema RAG (Retrieval Augmented Generation) para la búsqueda de sinónimos médicos, lo que permite localizar más fácilmente los códigos oficiales (SNOMED CT, RxNorm) requeridos por OMOP en una base de datos especialmente diseñada para ello. El sistema delega el trabajo en subagentes especializados en búsqueda terminológica, validación de códigos, construcción de SQL y verificación sintáctica.

Para evaluar la solución, he creado un dataset de prueba ad-hoc con 201 preguntas clasificadas por complejidad del SQL (baja, intermedia, compleja) y por dominios principales (condition, measurement, concept_relationship, etc.). Los resultados obtenidos muestran una **Validez Sintáctica y Estructural del SQL** en primer turno del **23.9%**, llegando al **84.9%** de media global si se interacciona 2 o 3 veces con el agente para ayudarle a mejorar la respuesta. La evaluación de la **Precisión Terminológica del Vocabulario** alcanza un sorprendente el muy alto **92.5%,** con un 90.0% de asignaciones perfectas que muy posiblemente puede estar influenciado por que la base de datos de evaluación no mostraba gran complejidad en esta dimensión.

Estos datos confirman una muy buena eficacia del agente para resolver conceptos médicos estandarizados, al tiempo que señalan los retos de la generación de SQL en consultas complejas con múltiples uniones. En conjunto, el proyecto demuestra la viabilidad de utilizar agentes conversacionales para democratizar el análisis de datos observacionales (ODS 3, 4, 9 y 10), aunque todavía existen claros potenciales de mejora de la herramienta.

Introducción

¿Cuántos profesionales clínicos/investigadores pueden analizar las fuentes de datos directamente en sus propias organizaciones (Atención Primaria o Secundaria, etc.) sin contar con conocimientos técnicos en bases de datos?

¿Cómo pueden los profesionales de la salud obtener respuestas a preguntas similares a las siguientes?

- Entre los pacientes recién diagnosticados de fibrilación auricular, ¿cuántos reciben una prescripción de warfarina?
- ¿Cuál es la edad promedio de los pacientes que se someten a una artroplastia de cadera?
- ¿Cuál es la tasa de incidencia de neumonía en pacientes mayores de 65 años?

Dependiendo de las capacidades de la organización y/o del usuario, la respuesta a estas preguntas puede gestionarse mediante:

1. La organización cuenta con una herramienta de inteligencia de negocios con informes diseñados específicamente para responder la pregunta en mente (ejemplos: Power BI, Tableau, OHDSI-Atlas, etc.), y el usuario tiene el conocimiento necesario para utilizarlos.
2. La organización cuenta con un equipo de bioinformáticos clínicos que puede proporcionar al usuario la respuesta final o algunas tablas de resumen para que el usuario las analice con hojas de cálculo u otras herramientas analíticas (R/Python/etc.).
3. El usuario tiene el conocimiento técnico (principalmente, el esquema de la base de datos clínica) para interactuar (a través de SQL u otro lenguaje) directamente con la base de datos (lo que requiere permiso de acceso), evitando extraer información de identificación personal (conocimiento de PII / GDPR).

Por lo tanto, las soluciones actuales no están ayudando a todos los usuarios potenciales.

¿Qué es el OMOP CDM (OHDSI)?

El Observational Medical Outcomes Partnership (OMOP) Common Data Model (CDM) es un estándar de datos comunitario abierto, respaldado por la comunidad OHDSI (Observational Health Data Sciences and Informatics), y diseñado para estandarizar la estructura y el contenido de los datos observacionales y permitir análisis eficientes que produzcan evidencia confiable.

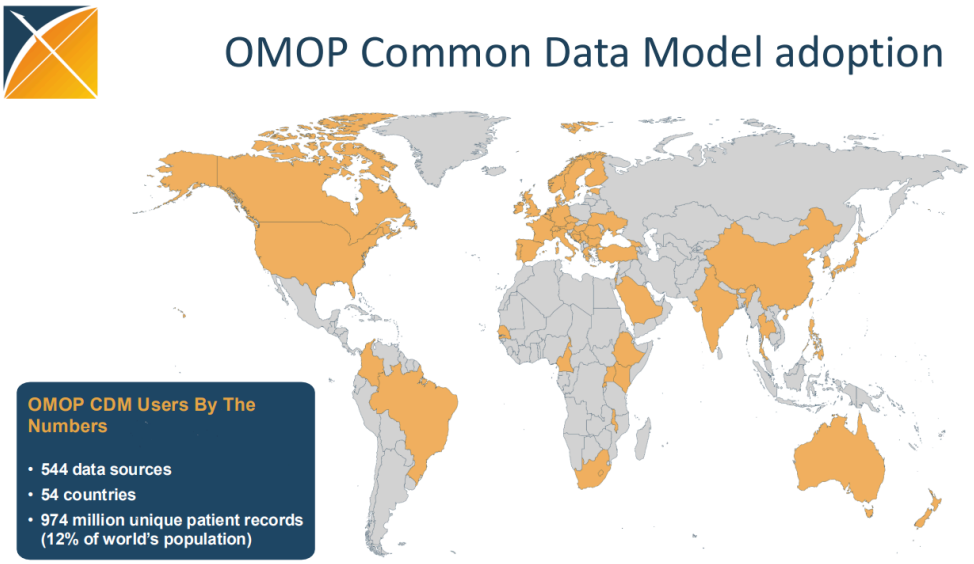


Figura 1. Tomado de *State of the OHDSI community* (p. 16), por G. Hripcsak, 2025, Observational Health Data Sciences and Informatics (https://www.ohdsi.org/wp-content/uploads/2025/10/OHDSI2025-Hripcsak-State-of-Community.pdf).

En resumen, OMOP es un diseño de esquema común de una base de datos clínica adoptado por 544 Socios de Datos de Salud en 54 países, con 974 millones de Registros Únicos de Pacientes (2025), y es la base para el análisis colaborativo de la salud (por ejemplo, la red europea Eden) en el ámbito clínico y de la salud.

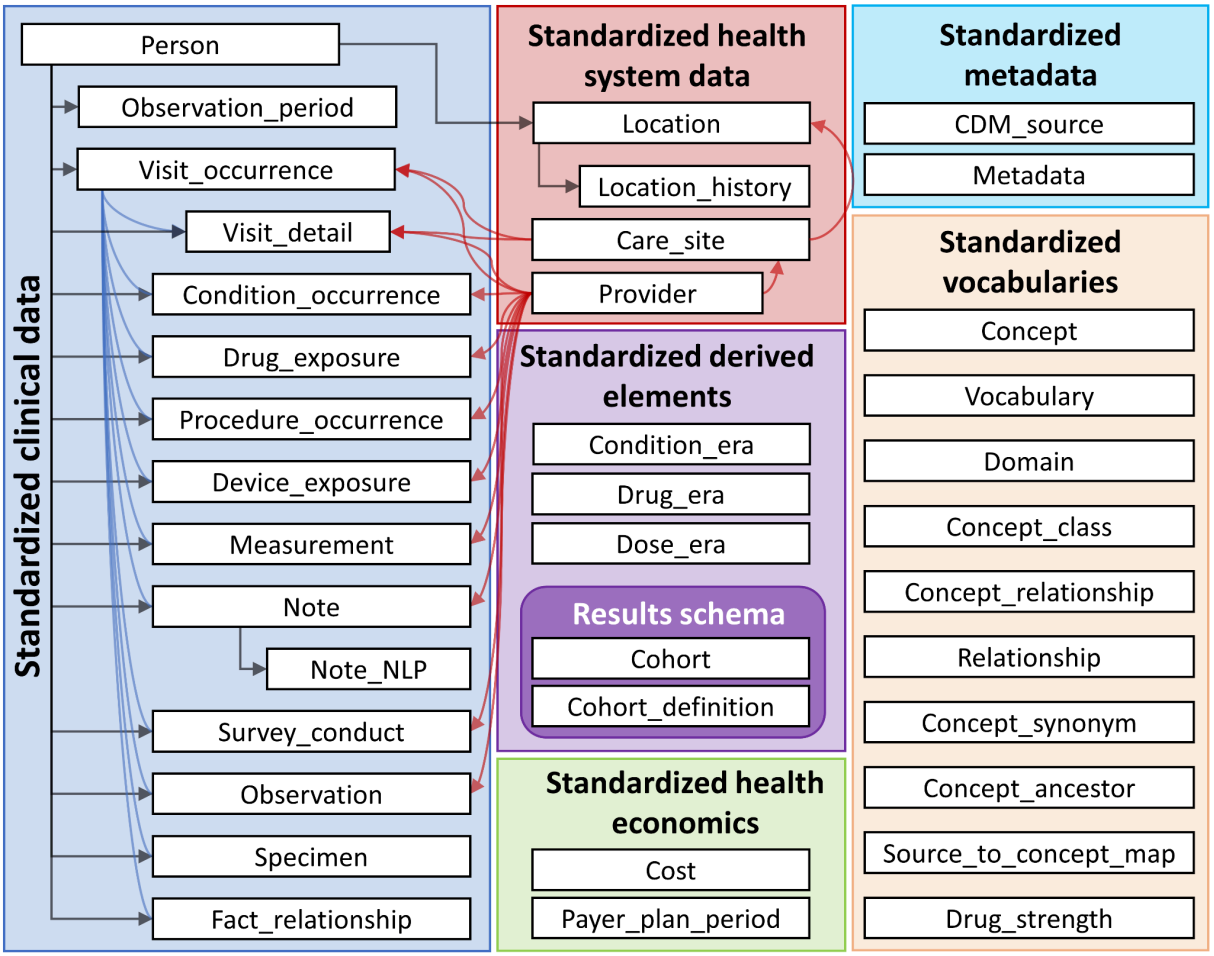


Figura 2. Nota. Adaptado de Data standardization: OMOP Common Data Model, por Observational Health Data Sciences and Informatics (OHDSI), n.d. (https://www.ohdsi.org/data-standardization/).

¿Qué son los análisis de IA conversacional?

La IA conversacional es un tipo de inteligencia artificial (IA) capaz de simular la conversación humana. Es posible gracias al procesamiento del lenguaje natural (PLN), un campo de la IA que permite a las computadoras comprender y procesar el lenguaje humano.

El Análisis Conversacional (AC) es un nuevo campo de la IA que aplica específicamente el procesamiento del lenguaje natural para extraer información analítica de bases de datos o almacenes de datos, permitiendo a los usuarios no técnicos formular preguntas sobre métricas, búsqueda y visualización de datos numéricos.

Prueba de concepto: el 'Agente Analítico OMOP'.

El objetivo fundamental de este trabajo ha sido la construcción de un agente basado en la aplicación de la tecnología de Análisis de IA Conversacional al Observational Medical Outcomes Partnership (OMOP) Common Data Model (CDM). Lo que pretendemos construir es:

- Crear un agente que permita a los usuarios de salud no expertos en bases de datos formular preguntas analíticas en lenguaje natural a fuentes de datos que utilicen el modelo de datos común OMOP.
- Por defecto, el agente encontrará los códigos OMOP en base a la descripción de la enfermedad, diagnóstico, medicamento, o cualquier otro concepto y proporcionará la consulta SQL para que el usuario interactúe con su propio entorno OMOP.

Ejemplo de preguntas a resolver por el 'Agente Analítico OMOP'

- Entre los pacientes recién diagnosticados de fibrilación auricular, ¿cuántos reciben una prescripción de warfarina?
- ¿Cuál es la edad promedio de los pacientes que se someten a una artroplastia de cadera?
- ¿Cuál es la tasa de incidencia de neumonía en pacientes mayores de 65 años?

Centrado principalmente en preguntas de caracterización que se formulan como:

- ¿Cuántos pacientes…?
- ¿Con qué frecuencia…?
- ¿Qué proporción de pacientes…?
- ¿Cuáles son los valores de laboratorio para los pacientes…?
- ¿Cuál es la duración media de la exposición en los pacientes en….?
- ¿Cuáles son las tendencias a lo largo del tiempo en…?
- ¿Qué otros medicamentos están usando estos pacientes?

Hipótesis y objetivos

Hipótesis

La implementación de un agente analítico basado en LLM (Large Language Models), integrado con el Common Data Model (CDM) de OMOP, que permita a profesionales sanitarios sin conocimientos técnicos de SQL ni de esquemas de bases de datos obtener respuestas precisas y resultados de caracterización clínica mediante el lenguaje natural.

Esta solución superará las barreras actuales de acceso a la información en las organizaciones de salud que utilicen el estándar OMOP y dependan de equipos especializados en bioinformática o de herramientas de BI complejas para responder preguntas sencillas.

Objetivos

Desarrollar un agente conversacional capaz de interactuar con bases de datos que cumplan con el estándar OMOP CDM para ejecutar, de forma automatizada, consultas de caracterización y de análisis de incidencia.

Objetivos específicos

Adaptar los metadatos de OMOP: Modificar y enriquecer el esquema de metadatos actual para que sea interpretable por un framework de agentes de IA.

Integrar Vocabularios Estándar: Implementar un motor de búsqueda de vocabularios (como SNOMED, ICT-10, etc.) para validar conceptos clínicos y sinónimos durante la conversación.

Generación Automatizada de SQL: Desarrollar la capacidad de traducir el lenguaje natural a consultas SQL válidas para el esquema OMOP, utilizando bibliotecas de consultas existentes como referencia.

Objetivos de desarrollo sostenible (ODS)

ODS 10: Reducción de las desigualdades

La premisa principal del agente es democratizar el acceso a los datos observacionales. Actualmente, existe una brecha y una profunda desigualdad entre las instituciones médicas que disponen de grandes presupuestos y de equipos especializados en bioinformática y los centros sanitarios o investigadores con recursos limitados.

Al proporcionar un software interactivo de lenguaje natural, permite que cualquier profesional o institución sanitaria —independientemente de sus recursos técnicos o de su presupuesto analítico— aproveche el potencial de la red global de datos basada en el estándar OMOP.

ODS 4: Educación de calidad

El proyecto contribuye de manera directa a la alfabetización en datos en el sector salud. Al integrar un sistema conversacional que traduce el lenguaje natural en consultas complejas estructuradas (SQL sobre OMOP CDM) y dotarlo de motores de búsqueda de vocabularios

estándar (SNOMED, ICD-10), la herramienta también funciona como un puente de aprendizaje.

Permite que investigadores y personal clínico sin formación técnica en bases de datos comprendan, de forma didáctica e intuitiva, las jerarquías de los términos médicos y la estructura de la información clínica internacional.

ODS 9: Industria, innovación e infraestructura

Con utilidades como el Agente OMOP, se podría reducir la dependencia de herramientas analíticas rígidas o de equipos bioinformáticos sobrecargados por consultas sencillas enviadas por el personal médico.

ODS 3: Salud y bienestar

El agente permite a los profesionales sanitarios (médicos, epidemiólogos, gestores de salud) extraer conocimiento crítico y ejecutar estudios de caracterización clínica e incidencia de manera inmediata y sin barreras técnicas. Esto acelera la toma de decisiones médicas basadas en la evidencia, lo que permite diagnósticos más rápidos y un seguimiento epidemiológico más eficiente ante crisis sanitarias.

Materiales y métodos

Esquema funcional y arquitectura técnica del agente

El agente requiere de dos diseños complementarios. Por una parte, el diseño funcional del agente, donde se especifican las tareas de cada subagente y como el orquestador utilizará los outputs de cada uno de los subagentes para mostrar al usuario el resultado final. Y por otra parte el diseño técnico de componentes tecnológicos (bases de datos, código, etc) que requiere este desarrollo.

Esquema funcional de agentes y subagentes

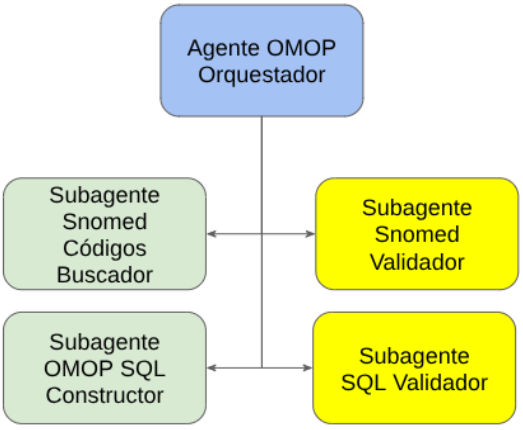


Figura 3. Agentes orquestador y subagentes

El sistema está compuesto por 5 agentes especializados en tareas específicas que a continuación describo:

Agente OMOP Orquestador: Es el nodo central y punto de entrada. Su función principal es descomponer la consulta médica recibida en subtareas y enviarlas a los subagentes. Al recibir la respuesta de los subagentes, genera la contestación final.

Subagente Snomed Códigos Buscador: Se responsabiliza de la extracción de entidades clínicas 'oficiales' (valores concept_id). Busca directamente el concepto descrito por el usuario en las bases de datos, en caso de no encontrarlo, genera sinónimos buscando en la base de datos RAG, y vuelve a buscar en la base de datos. Lo que devuelve al agente principal son los códigos que ha encontrado.

Subagente Snomed Validador: Actúa como mecanismo de control para chequear que la respuesta es correcta. Los concept_id deben haber sido generados por la búsqueda en la base de datos, no por el agente y su entrenamiento original. El objetivo principal del agente es eliminar las "alucinaciones" del modelo, y evitar que pueda ofrecer códigos que han nacido de su propio entrenamiento,

Subagente OMOP SQL Constructor: Se encarga de traducir la petición del usuario en una instrucción SQL. Examina el modelo de base de datos OMOP (Figura 2) y va iterando en la construcción de la SQL, hasta que devuelve una primera propuesta.

Subagente SQL Validador: Posiblemente, uno de los componentes más importantes del sistema, dado que comprueba directamente contra una base de datos OMOP que la SQL funciona correctamente. En caso de encontrar errores de sintaxis o de campos o de tablas,

devuelve el error al agente Constructor de SQL, para que le ofrezca una nueva alternativa. Este proceso se repite hasta que la SQL es 100% válida

El flujo de comunicación de los agentes funciona de la siguiente manera:

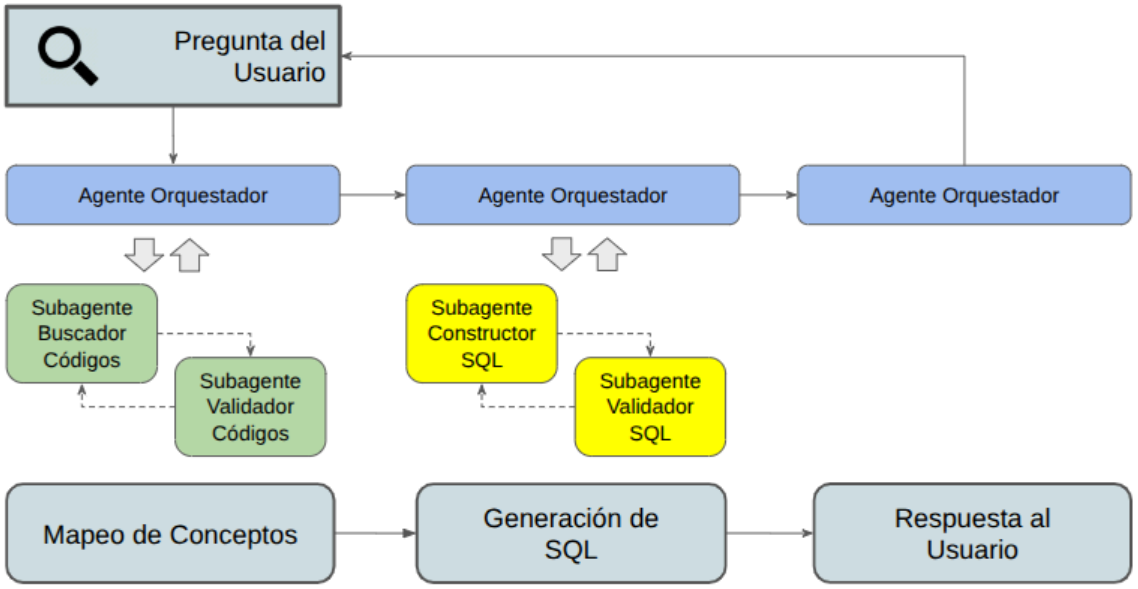


Figura 4. Flujo de interacciones entre los agentes y el usuario

Al recibir la pregunta del usuario, lo primero que hace el agente orquestador es asignar la tarea de identificación de códigos para todos los conceptos médicos que aparecen en la pregunta. Los dos subagentes de códigos (buscador y validador) interaccionan entre sí hasta que localizan correctamente los concept_id involucrados, y se los devuelve al orquestador.

Con esos códigos en memoria, el orquestador se lo pasa al sub agente constructor de SQL que va generando propuestas que validan en el subagente validador de SQL. Estos dos sub agentes también interactúan hasta que la SQL queda completamente validada, y es devuelta al orquestador.

El orquestador presenta al usuario, la SQL a la que une una explicación de que hace cada parte de la SQL para que el usuario pueda interpretar mejor el resultado, y que pueda solicitar cambios a la SQL si lo cree conveniente.

Arquitectura técnica

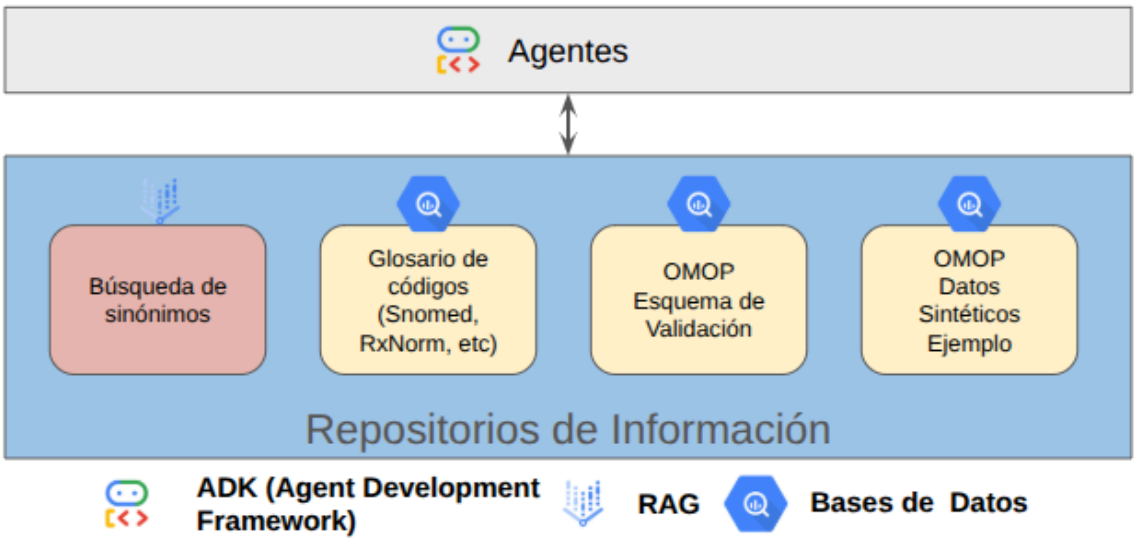


Figura 5. Arquitectura técnica

Todo el sistema ha sido desarrollado en la plataforma Google Cloud con los siguientes componentes técnicos principales:

Agentes: Desarrollado a través del framework ADK (Agent Development Kit) cuyo flujo ha sido explicado en el anterior punto, y desplegado utilizando Docker a través de Cloud Build en un entorno test web utilizando Google Cloud Run. El modelo utilizado dentro de los agentes es Gemini 2.5 flash, aunque el framework es agnóstico y podría cambiarse por cualquier otro.

Sistema RAG (Retrieval-Augmented Generation). Es el motor vectorial que busca las correspondencias más relevantes en función de los textos médicos introducidos por el usuario. El componente técnico utilizado es el Google Cloud Vertex AI Search

Bases de Datos o capa de persistencia. Los diferentes datasets (conjunto de tablas) que utilizan los subagentes para consultar y validar la información. Las tres bases de datos están desarrolladas en la base de datos Google Cloud Bigquery. Las tres bases de datos que se utilizan son:

- Glosario de Términos o repositorio con los vocabularios estandarizados del sistema OMOP,
- OMOP Esquema de validación: Es una estructura de metadatos y esquemas que utiliza el validador para confirmar que la SQL diseñada sigue las normas del modelo.

- OMOP Datos Sintéticos Ejemplo: Base de datos OMOP con datos simulados sobre la que se ejecutan las consultas finales y se extraen los datos.

Acceso al agente OMOP

El agente estará accesible y operativos en el siguiente vínculo:

Entorno Desarrollo Agente (Uso bajo solicitud de acceso)

Código

El repositorio github incluye el código del agente, el código de evaluación y los anexos

https://github.com/sogire/tfm-ue-bioinformatica2526-agente-omop

Metodología de evaluación de resultados

Para evaluar la efectividad, precisión y fiabilidad del sistema multi-agente, he diseñado un marco experimental estructurado en dos fases complementarias:

1. **Evaluación Cualitativa:** Enfocada en demostrar el correcto funcionamiento operativo y de interacción del agente frente a consultas de distinta naturaleza.
2. **Evaluación Cuantitativa:** Diseñada para medir de forma objetiva la precisión terminológica, la sintaxis SQL y la exactitud de los datos recuperados.

1. Evaluación cualitativa (Demostración funcional del agente)

Esta primera fase tiene como objetivo validar cualitativamente el flujo de interacción, la capacidad del agente orquestador para coordinar los subagentes y la claridad de los resultados presentados al usuario. A través de este análisis se demuestra que el agente es funcional y capaz de resolver preguntas reales en lenguaje natural.

- **Ejemplo 1: Consulta analítica (Diabetes)**
  - **Pregunta de usuario:** *"Genera una SQL para visualizar el número de pacientes con diabetes por años"*
  - **Flujo del agente:**
    1. Identifica y valida el concepto estandarizado más relevante: 201820: Diabetes mellitus (SNOMED).
    2. Construye y valida la instrucción SQL agrupada por año.
    3. Retorna la consulta SQL estructurada junto con una explicación didáctica paso a paso de cada cláusula (SELECT, FROM, WHERE, GROUP BY, ORDER BY)
    4. Se itera en la respuesta para mejorar la SQL.

- **Ejemplo 2: Mapeo y extracción terminológica (Demencia)**
    - **Pregunta de usuario:** *"Genera un listado de los principales códigos para analizar la demencia."*
    - **Flujo del agente:** El subagente de búsqueda y validación de vocabularios extrae de la base de datos de metadatos los conceptos relacionados, estructurándolos en una tabla ordenada con su OMOP concept_id, nombre del concepto y código de origen SNOMED Code

2. Evaluación cuantitativa

Esta segunda fase efectúo una validación sistemática sobre un conjunto de datos controlado. El objetivo no es solo conseguir una cuantificación general del sistema, sino además señalar en qué casos específicos el sistema requiere ser mejorado.

Conjunto de datos de evaluación

El conjunto de datos de evaluación, denominado Gold Standard (Anexo C), está compuesto por 201 de preguntas clínicas en español formuladas en lenguaje natural y emparejadas con sus correspondientes consultas SQL. Dichas consultas se categorizan según su dominio clínico principal en OMOP CDM 5.4 (por ejemplo, condition, measurement o concept_relationship) y su nivel de complejidad sintáctica: baja (consultas directas o con uniones simples de catálogo), intermedia (múltiples uniones, agregaciones o subconsultas) y compleja (expresiones CTE, funciones de ventana o subconsultas anidadas avanzadas).

Para la construcción ad hoc de este conjunto de pruebas se tomaron como referencia las consultas estandarizadas de la QueryLibrary de la comunidad OHDSI.

Ejemplo de pregunta a evaluar: "*Listar todas las condiciones y enfermedades clínicas cuya localización anatómica corresponda al concepto 4103720 (articulación de la rodilla)*". A continuación añado el ejemplo de la ficha.

```
None
## Ficha Ejemplo de Pregunta Gold Standard ##

id_evaluacion: "querylibrary_C11"
nivel_complejidad: "intermedia"
domain_main: "concept"
domain_others: "concept_relationship"
pregunta_lenguaje_natural: >-
```

```
   Listar todas las condiciones y enfermedades clínicas cuya localización anatómica corresponda al concepto 4103720 (articulación de la rodilla).
sql_base_gold_standard: |
  SELECT
    a.concept_id       AS condition_id,
    a.concept_name     AS condition_name,
    a.concept_code     AS condition_code,
    a.concept_class_id AS condition_class,
    a.vocabulary_id    AS condition_vocab_id,
    d.concept_id       AS anatomical_site_id,
    d.concept_name     AS anatomical_site_name,
    d.concept_code     AS anatomical_site_code,
    d.concept_class_id AS anatomical_site_class,
    d.vocabulary_id    AS anatomical_site_vocab_id
  FROM `bio-med-480108.OMOP_54_A.concept_relationship` AS cr
        JOIN `bio-med-480108.OMOP_54_A.concept` AS a ON cr.concept_id_1 = a.concept_id
        JOIN `bio-med-480108.OMOP_54_A.concept` AS d ON cr.concept_id_2 = d.concept_id
  WHERE
    cr.relationship_id = 'Has finding site' AND
    d.concept_id = 4103720 AND
    cr.invalid_reason IS NULL
  ;
concept_ids_gold_standard: "4103720"
```

Figura 6. Ejemplo de definición de consulta “Gold Standard”

Métricas de Evaluación

Realizo la validación con un enfoque multidimensional para evaluar las diferentes características de una respuesta.

1. **Validez Sintáctica y Estructural:** Mide el porcentaje de consultas SQL generadas por el agente que son sintácticamente válidas y ejecutables sin error en el motor de base de datos.
    - Métrica: Ratio de SQL Válidas sobre el total de SQL evaluadas

2. **Precisión Terminológica del Vocabulario** utilizado: Evalúa el porcentaje de identificadores estandarizados (concept_id de SNOMED CT, RxNorm, etc.) correctamente identificados por los subagentes y el sistema RAG
    - Métrica: Ratio de Concept_id correctamente identificados sobre el total de conceptos a identificar en la consulta.

Procedimiento de evaluación

He construido un script Python, incluido en los anexos, que sigue el siguiente flujo para cada registro.

1. Invocación: Se envía la pregunta en lenguaje natural al Agente OMOP.
2. Ejecución y Extracción: Registro de la SQL producida por el agente.
3. Comprobación de Sintaxis de SQL y registro de la métrica de Validez Sintáctica y Estructural (VSE).
4. Comprobación y registro de la métrica 'Precisión Terminológica del Vocabulario'
5. Si la respuesta no es correcta en la iteración primera (turno 1), se interacciona de forma seguida hasta el turno 3, límite de la evaluación.
6. Consolidación: Tabulación de los resultados de ejecución y de los errores de ejecución.

Ejemplo de resultado de la evaluación

```
None
id_evaluacion: querylibrary_C11
session_id: 2e03cfd2-498e-4aba-90cb-ea989fa56588
session_file: sessions/C11.json
turnos_ejecutados: 1
sql_generada_agente: |-
  SELECT c.concept_id,
         c.concept_name,
         c.domain_id
  FROM `bio-med-480108.omop_54_a.concept` c
     JOIN  `bio-med-480108.omop_54_a.concept_ancestor`  ca  ON  c.concept_id  =
ca.descendant_concept_id
  WHERE ca.ancestor_concept_id = 4103720
    AND c.domain_id = 'Condition'
    AND c.standard_concept = 'S'
concept_ids_identificados_agente:
```

```
- 4103720
metricas_evaluacion:
  validez_sintactica_y_estructural: 1.0
  precision_terminologica_vocabulario: 1.0
  metricas_por_turno:
    turno_1:
      validez_sintactica_y_estructural: 1.0
      precision_terminologica_vocabulario: 1.0
      question_improvement: ''
evaluacion_cualitativa: |-
     Generación directa de consulta SQL válida sobre tabla(s) CONCEPT,
CONCEPT_ANCESTOR en un único turno con validación exitosa en BigQuery.
    Precisión terminológica óptima: identificó y utilizó todos los conceptos
requeridos ([4103720]).
check_conexion: true
```


Figura 7. Ejemplo de Resultado de la evaluación

Para realizar una evaluación rigurosa y reproducible del agente analítico, desarrollé un marco de pruebas automatizado que he denominado ‘tfm-eval’ que he incluido en el github del proyecto. Este sistema utiliza scripts en Python (run_query_evaluation.py y analyze_evaluation_results.py) que interactúan directamente con el agente OMOP alojado en Google Cloud Run.

Esta infraestructura permite capturar las respuestas del agente en tiempo real, registrar el uso de herramientas internas y guardar un historial completo de cada sesión para analizar su rendimiento y calcular las métricas.

El proceso de evaluación sigue un protocolo de diálogo progresivo de hasta tres turnos para guiar al agente cuando la consulta requiere aclaraciones. En el Turno 1, se envía la pregunta médica en español solicitando una consulta SQL válida para OMOP CDM 5.4, y se confirman los primeros códigos o conceptos propuestos por el sistema. Si el agente no genera el código inmediatamente, el evaluador pasa al Turno 2, donde confirma formalmente los conceptos identificados e incluye información sobre las tablas o dominios implicados (domain_main y domain_others). Por último, si el agente aún no ha devuelto la consulta, en el Turno 3 se le solicita de manera directa que entregue únicamente la sentencia SELECT final lista para ser ejecutada

Resultados

Resultados cualitativos

Ejemplo 1: Consulta analítica (Diabetes)

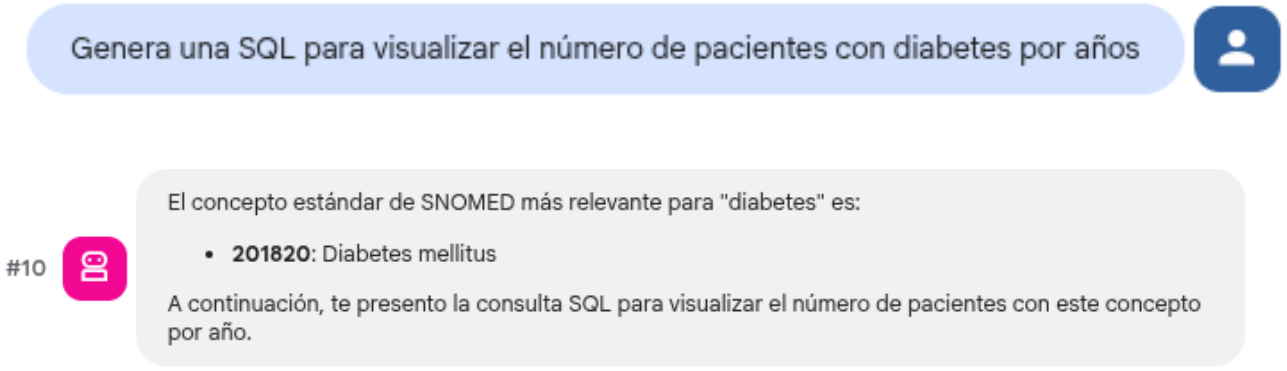


Figura 8. Interacción con el agente OMOP: Identificación del concepto médico

El sistema localiza e identifica correctamente la enfermedad en el vocabulario SNOMED y devuelve el código OMOP a utilizar en la query posterior.

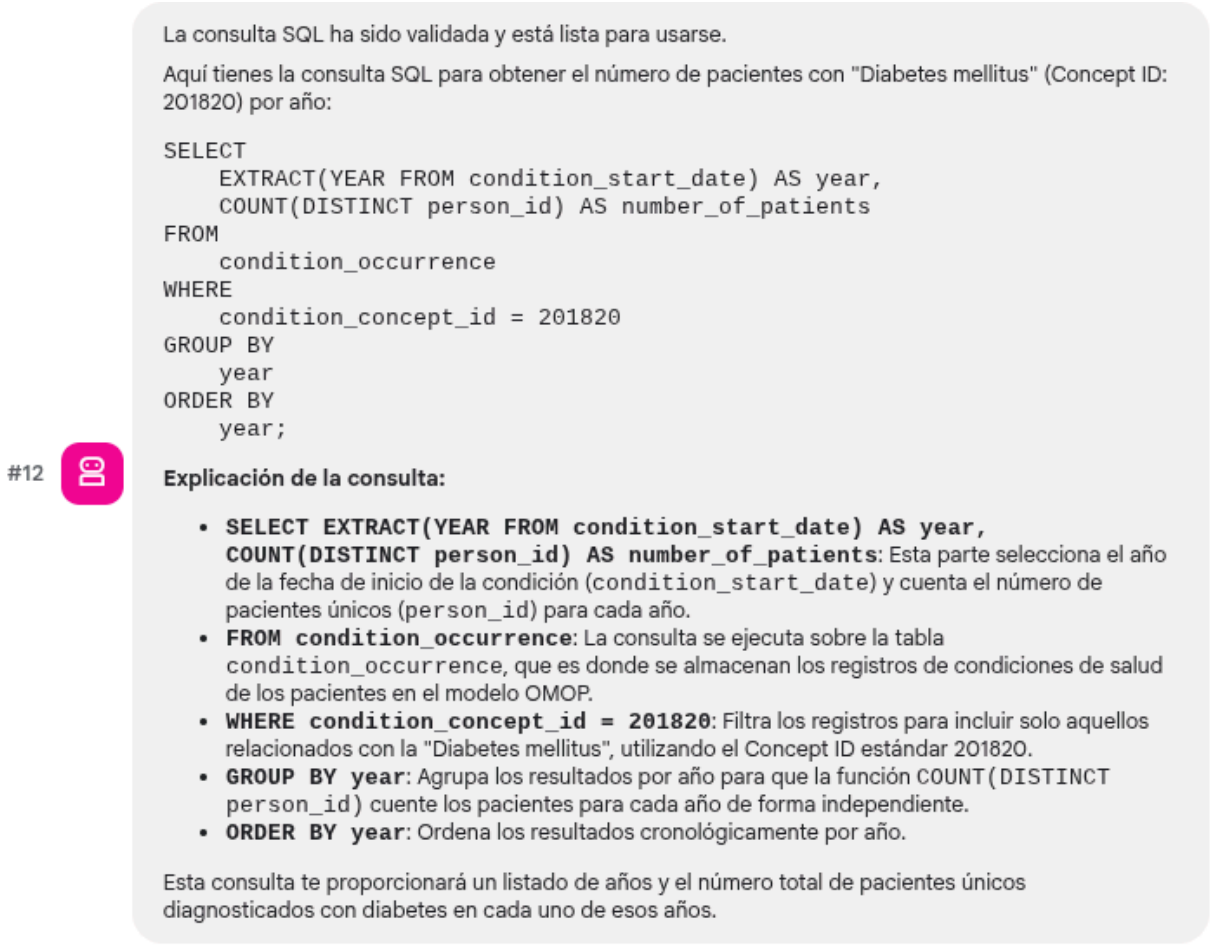


Figura 9. Interacción con el agente OMOP: Generación de la SQL validada y con explicación de la decisión

A continuación genera una SQL que está validada y es funcional porque la ha probado contra una base de datos real. Añade también una explicación de la SQL generada para que el clínico o usuario pueda realmente comprobar que los datos que va a devolver, son exactamente los que quería obtener. Esta explicación es básica para permitir al clínico o usuario ir mejorando la consulta a través de posteriores interacciones.

Por ejemplo, al solicitar que queremos que no solo extraiga el concepto comentado, sino también todos sus descendientes, el agente responde con una modificación de la SQL totalmente correcta y de nuevo validada.



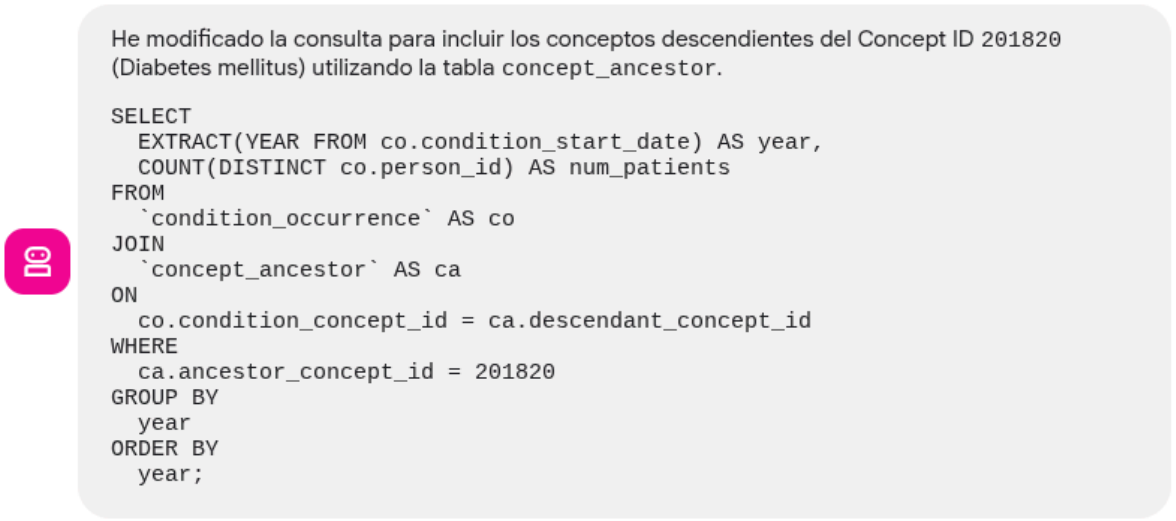


Figura 10. Interacción con el agente OMOP: Mejora de la respuesta en base a la petición del usuario

Ejemplo 2: Mapeo y extracción terminológica (Demencia)

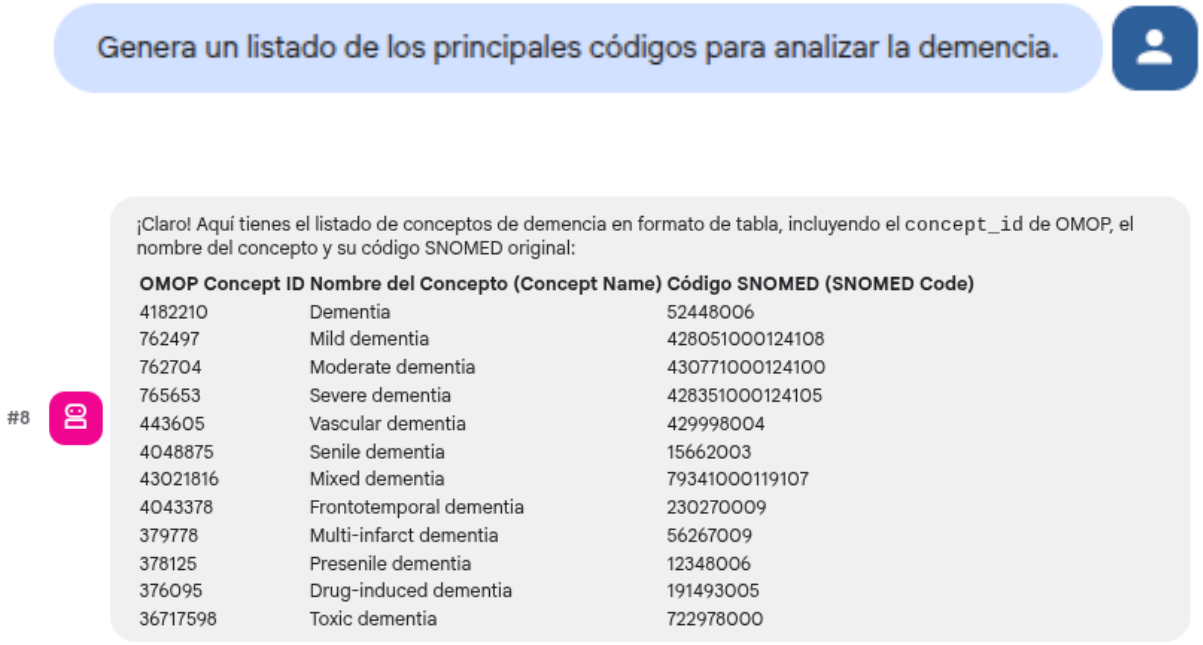


Figura 11. Interacción con el agente OMOP: Búsqueda de los códigos OMOP más cercanos al concepto médico de la pregunta del usuario

El subagente de búsqueda y validación de resultados extrae unos primeros ejemplos, los más importantes, que coinciden con el concepto buscado.

Video demostrativo del agente en funcionamiento (Link a Vídeo Online)

Resultados cuantitativos

El listado "Gold Standard" finalmente utilizado está compuesto por 201 preguntas test, clasificada según nivel de complejidad: 26 preguntas de baja complejidad, 71 de intermedia complejidad y 104 de alta complejidad.

En la Tabla 1 se reportan los estadísticos descriptivos globales obtenidos tras el protocolo completo de evaluación. Los resultados globales muestran una sólida **Validez Sintáctica y Estructural** con una media de 0,849 (±0,271) y una mediana de 0,950, destacando una alta ejecutabilidad SQL media de 0,094 sobre 0,10 y una similitud estructural de 0,756 sobre 0,90. Asimismo, la **Precisión Terminológica del Vocabulario** alcanzó un promedio elevado de 0,925 (±0,239) con una mediana de 1,000, requiriendo un promedio de 2,100 turnos conversacionales ejecutados (con una mediana de 2,0 turnos) para alcanzar estos niveles de desempeño.

Tabla 1.

Estadísticos Descriptivos Globales del Desempeño del Agente (N = 201).

Métrica Evaluada	N	Media +/- DE	Mediana [IQR]	Mín - Máx	IC 95% Media
Validez Sintáctica y Estructural (Final)	201	0.849 +/- 0.271	0.950 [0.130]	0.00 - 1.00	[0.811 - 0.887]
Criterio 1.1: Ejecutabilidad SQL (Max. 0.10)	201	0.094 +/- 0.025	0.100 [0.000]	0.00 - 0.10	[0.090 - 0.097]
Criterio 1.2: Similitud Estructural Gold Standard (Max. 0.90)	201	0.756 +/- 0.251	0.850 [0.130]	0.00 - 0.90	[0.721 - 0.790]
Precisión Terminológica Vocabulario (Final)	201	0.925 +/- 0.239	1.000 [0.000]	0.00 - 1.00	[0.892 - 0.958]
Turnos Conversacionales Ejecutados	201	2.100 +/- 0.755	2.000 [1.000]	1.00 - 3.00	[1.994 - 2.205]

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

Resultados por nivel de complejidad

La estratificación del resultado según el nivel de dificultad técnica —baja (N = 26, 12.9%), intermedia (N = 71, 35.3%) y compleja (N = 104, 51.7%)— demuestra que el agente exhibe una altísima solidez en consultas de rango bajo y medio, pero que se encuentra con retos específicos que superar ante las preguntas avanzadas (complejas).

Tabla 2.

Rendimiento Comparativo por Nivel de Complejidad

Nivel de Complejidad	N (% total)	Validez Sintáctica Media (+/- DE)	Validez Mediana [IQR]	Vocabulario Medio (+/- DE)	Tasa Resolución (Validez > 0.80)	Precisión Vocabulario Perfecta (= 1.00)
Baja	26 (12.9%)	0.928 +/- 0.146	0.980 [0.040]	1.000 +/- 0.000	92.3% (24/26)	100.0% (26/26)
Intermedia	71 (35.3%)	0.932 +/- 0.167	0.980 [0.040]	0.967 +/- 0.139	95.8% (68/71)	94.4% (67/71)
Compleja	104 (51.7%)	0.773 +/- 0.326	0.950 [0.242]	0.877 +/- 0.304	69.2% (72/104)	84.6% (88/104)

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

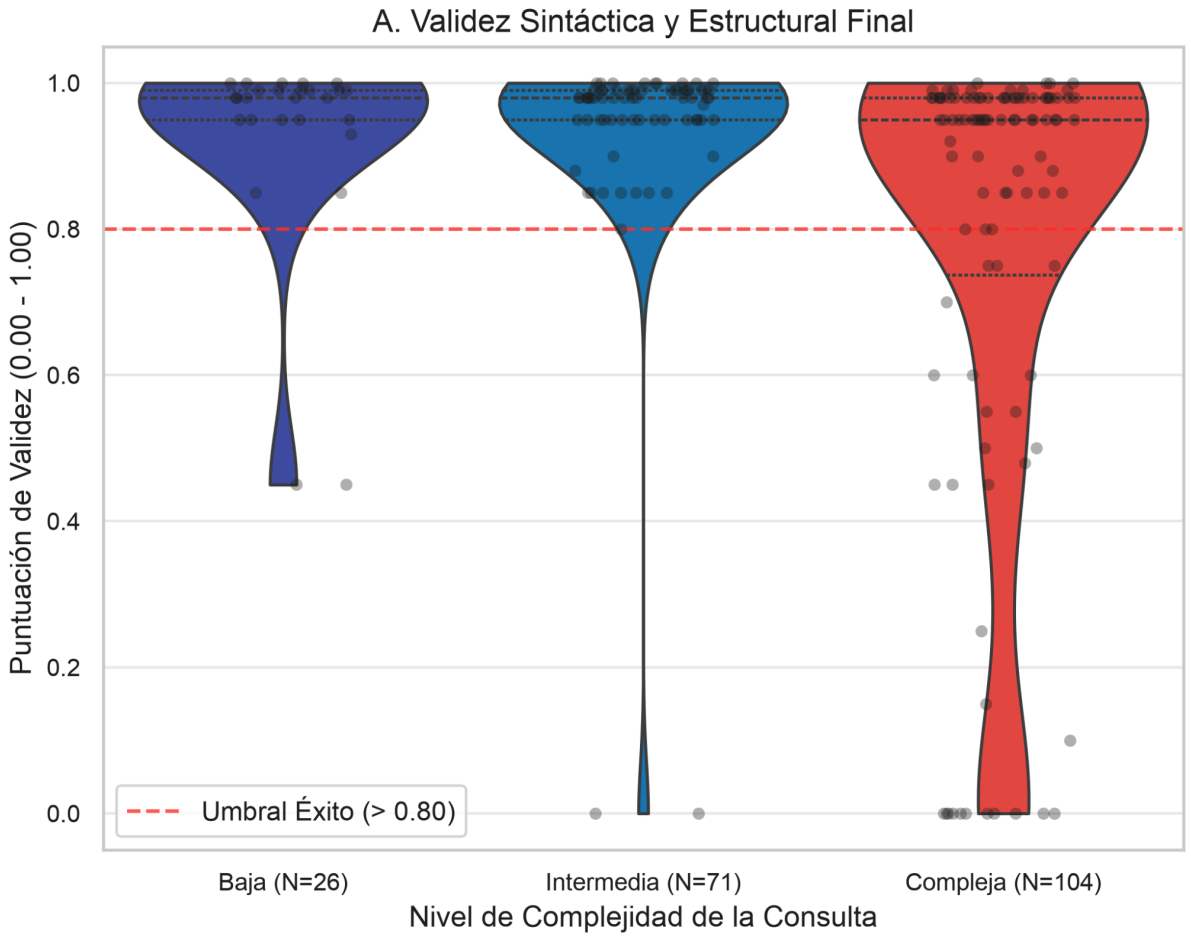


Figura 12. Distribución del Rendimiento del Agente OMOP por Nivel de Complejidad. Panel A: Puntuación de Validez Sintáctica y Estructural Final. Las líneas discontinuas representan los umbrales de éxito operativo (0.80) y asignación perfecta (1.00).

Los contrastes no paramétricos de Kruskal-Wallis confirmaron diferencias estadísticamente significativas entre los tres estratos tanto para la Validez Sintáctica: 23.61, $p < 0.001$, como para la Precisión Terminológica: 8.12, $p = 0.017$. El análisis post-hoc reveló que el rendimiento en complejidad baja e intermedia no difiere de forma significativa ($Z = 0.28$, p-ajustada = 0.782), mientras que las consultas complejas experimentan una caída significativa frente a la intermedia ($Z = 4.34$, p-ajustada < 0.001) y frente a la baja ($Z = 3.33$, p-ajustada = 0.002).

Resultados por dominio OMOP CDM

Al analizar el desempeño según la tabla o dominio principal del modelo OMOP CDM 5.4, se observan diferencias importantes.

Tabla 3.

Rendimiento del Agente Desglosado por Dominio Principal OMOP

Dominio Principal OMOP	N (% total)	Validez Sintáctica Media (+/- DE)	Validez Mediana	Precisión Vocabulario Media	Turnos Medios	Tasa Éxito (> 0.80)
concept	51 (25.4%)	0.879 +/- 0.194	0.950	0.975	2.140	0.824
drug_exposure	43 (21.4%)	0.798 +/- 0.355	0.980	0.956	2.230	0.791
condition_era	26 (12.9%)	0.662 +/- 0.387	0.850	0.795	2.580	0.577
condition_occurrence	23 (11.4%)	0.945 +/- 0.058	0.980	0.830	1.570	0.957
drug_era	20 (10.0%)	0.821 +/- 0.303	0.980	0.866	2.600	0.700
observation_period	20 (10.0%)	0.931 +/- 0.113	0.980	1.000	1.650	0.950
person	9 (4.5%)	0.984 +/- 0.005	0.980	1.000	1.220	1.000
cost	3 (1.5%)	0.947 +/- 0.045	0.950	1.000	2.330	1.000
care_site	2 (1.0%)	0.975 +/- 0.035	0.975	1.000	1.000	1.000
payer_plan_period	2 (1.0%)	0.970 +/- 0.028	0.970	1.000	1.500	1.000
vocabulary	2 (1.0%)	0.965 +/- 0.021	0.965	1.000	3.000	1.000

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

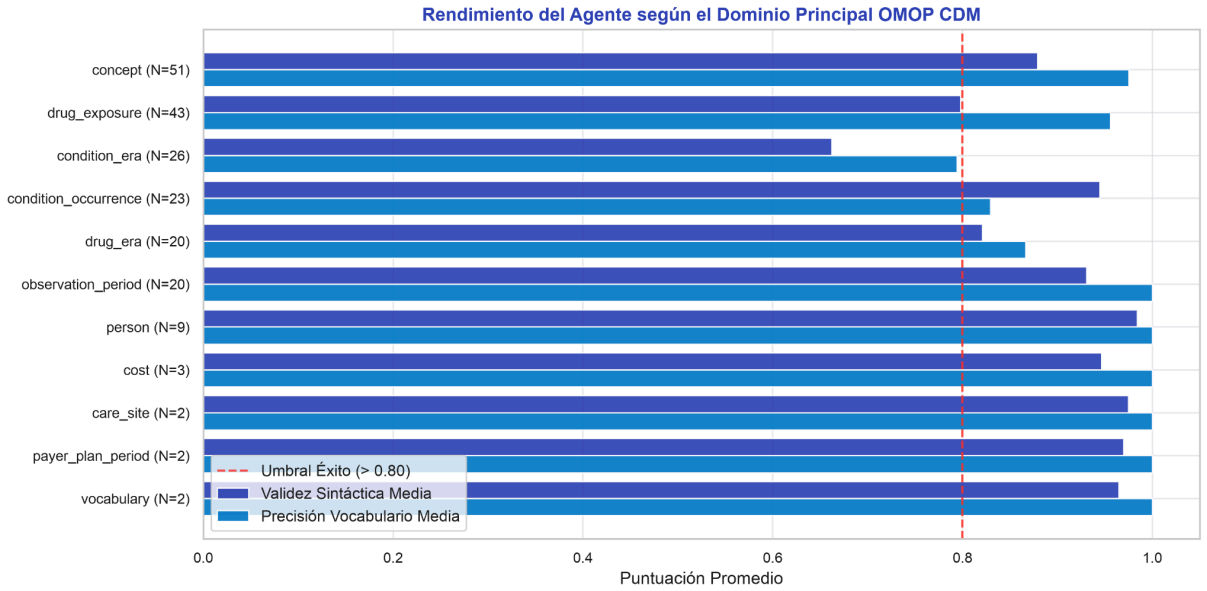


Figura 13. Rendimiento Promedio del Agente según el Dominio Principal OMOP CDM. Comparación entre Validez Sintáctica Media y Precisión Terminológica de Vocabulario frente al umbral de corte del 80%.

Las diferencias de validez entre dominios resultaron estadísticamente significativas (Kruskal-Wallis: 15.65, p = 0.016). Las tablas directas de eventos clínicos y demografía (person, care_site, condition_occurrence, observation_period) obtuvieron tasas de éxito excepcionales (>= 95.0%). Por el contrario, las tablas derivadas de persistencia clínica (Eras), y en particular condition_era, conformaron el dominio más desafiante con una validez media de solo 0.662 y una tasa de resolución del 57.7%.

La comparación formal entre tablas de ocurrencias crudas (condition_occurrence) frente a tablas de épocas agregadas (condition_era) evidenció una penalización estadísticamente significativa del modelo (prueba Mann-Whitney: 167.0, p = 0.0078). Esto demuestra que el agente interpreta con facilidad la existencia puntual de diagnósticos, pero sufre ante la lógica de periodos continuados de exposición o enfermedad consolidados en las tablas _era.

Resultados por nivel de complejidad y turno de resolución

Los resultados de la evaluación del agente analítico sobre un conjunto de 201 consultas muestran una alta precisión terminológica del vocabulario (92.5%). En cuanto a la validez sintáctica y estructural del SQL, el sistema alcanza un 23.9% de éxito en el primer turno, elevándose hasta una media global del 84.9% (y un 81.6% de éxito operativo) tras un proceso de refinamiento conversacional de hasta tres turnos. Si bien las consultas de complejidad baja e intermedia se resolvieron de forma muy eficiente, las consultas complejas

requieren mayor esfuerzo iterativo, evidenciando los retos en la generación automática de SQL avanzadas.

Tabla 4.

Tabla de Contingencia: Nivel de Complejidad x Turnos Conversacionales Ejecutados

Nivel de Complejidad (N, % Fila)	Turno 1	Turno 2	Turno 3	Total
Baja	12 (46.2%)	7 (26.9%)	7 (26.9%)	26 (100.0%)
Intermedia	20 (28.2%)	38 (53.5%)	13 (18.3%)	71 (100.0%)
Compleja	16 (15.4%)	40 (38.5%)	48 (46.2%)	104 (100.0%)
Total Global	**48 (23.9%)**	**85 (42.3%)**	**68 (33.8%)**	**201 (100.0%)**

Notas: N: Tamaño de Muestra. DE: Desviación Estándar. IQR: Rango intercuartílico. Mín - Máx: Valores mínimo y máximo observados. IC 95% Media: Intervalo de confianza al 95% para la media.

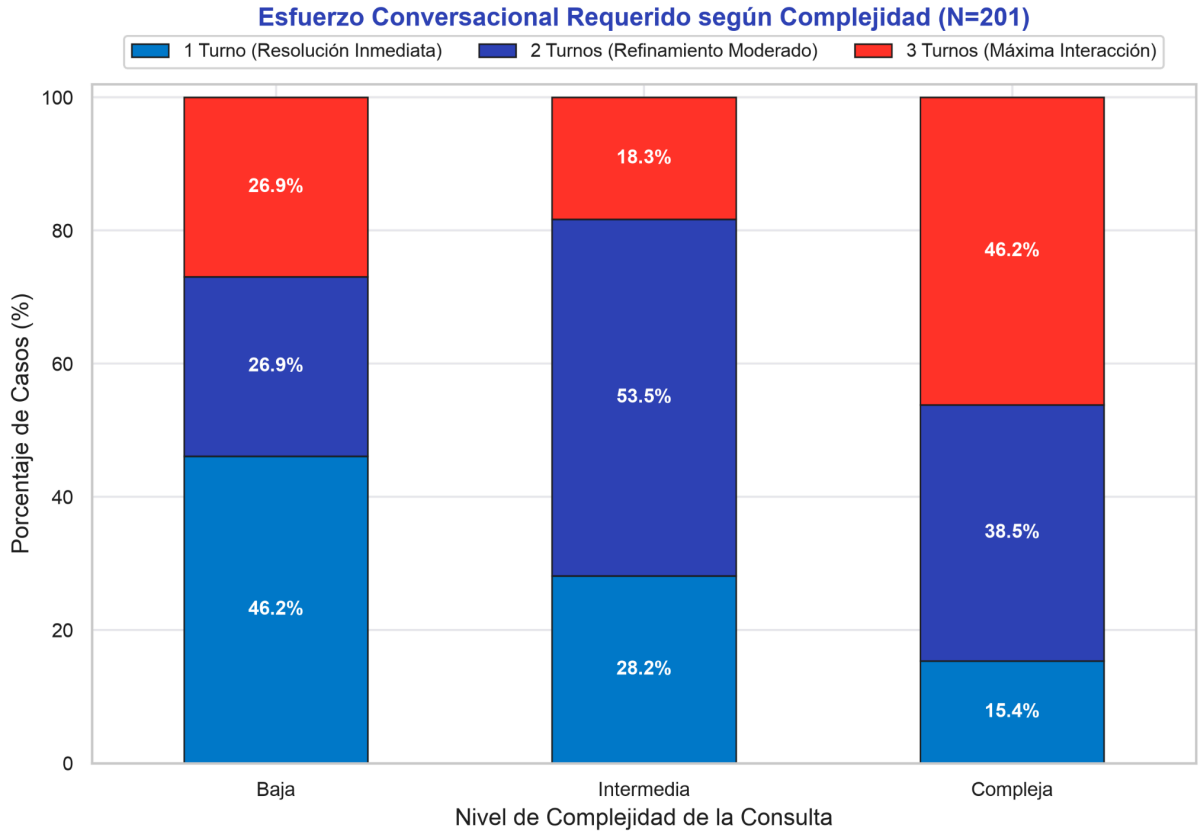


Figura 14. Esfuerzo Conversacional Requerido según la Complejidad de la Consulta (N = 201). Proporción de casos resueltos en Turno 1 (resolución directa), Turno 2 (refinamiento moderado) y Turno 3 (máxima interacción).

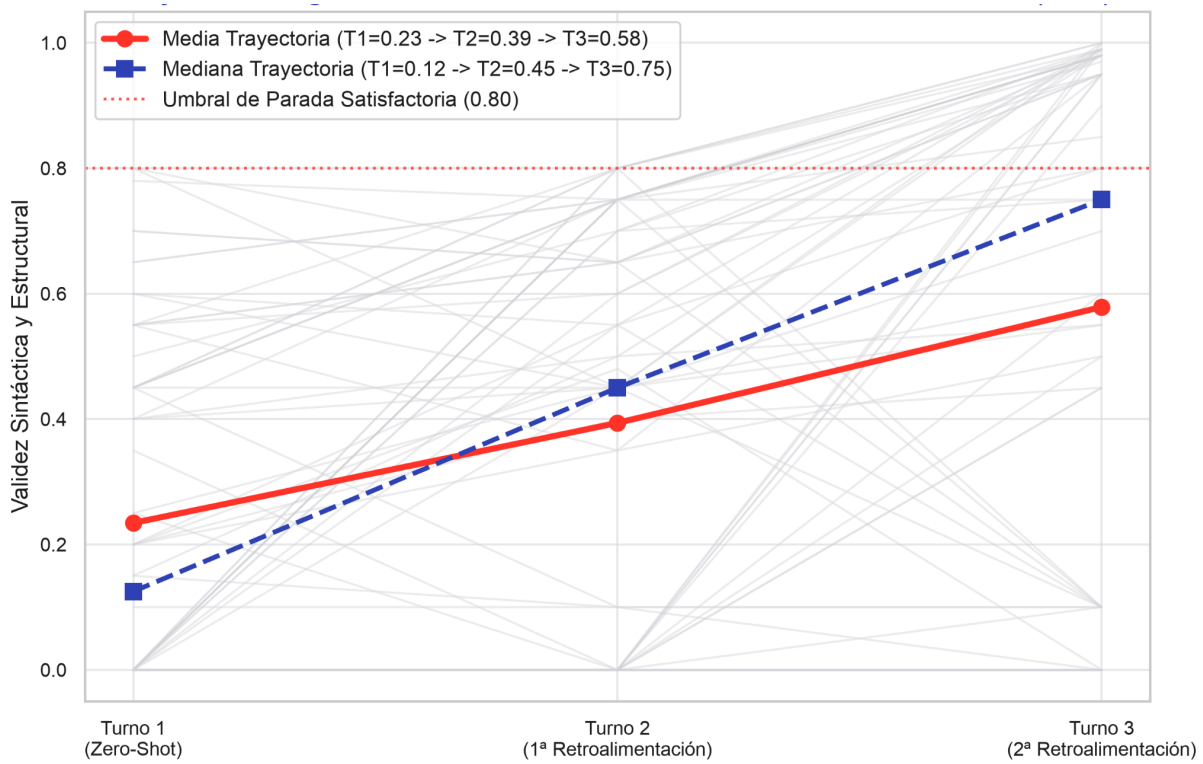


Figura 15.Trayectoria de la mejora de resultados en base a los turnos

La prueba de independencia confirmó una fuerte asociación entre la complejidad de la consulta y el número de turnos necesarios (Chi-cuadrado = 23.11, p = 0.0001). Mientras que en complejidad baja casi la mitad de los casos (46.2%) se resolvieron de forma inmediata en el primer turno (media de 1.81 +/- 0.85 turnos), en complejidad alta solo el 15.4% fue resuelto en primera instancia (zero-shot), requiriendo un 46.2% de las consultas agotar el tercer turno (media de 2.31 +/- 0.73 turnos).

Efecto del Refinamiento Iterativo

La aportación del diálogo guiado sobre el agente queda demostrada cuantitativamente en la curva de resolutividad acumulada.

Tabla 5.

Progresión del Desempeño y Ganancia Neta (Delta) por Turno

Transición Evaluada	Cohorte (N)	Validez Inicial	Validez Final	Delta Validez Medio (Mediana)	Casos que Mejoran (N, %)	Prueba de Wilcoxon (W, p)
Turno 1 -> Turno 2	153	0.316 +/- 0.318	0.708 +/- 0.356	+0.392 (+0.350)	118 (77.1%)	W = 264.0 p < 0.001

Transición Evaluada	Cohorte (N)	Validez Inicial	Validez Final	Delta Validez Medio (Mediana)	Casos que Mejoran (N, %)	Prueba de Wilcoxon (W, p)
Turno 2 -> Turno 3	68	0.394 +/- 0.352	0.579 +/- 0.421	+0.185 (+0.195)	45 (66.2%)	W = 247.5 p < 0.001
Turno 1 -> Consolidado Final	**201**	**0.468 +/- 0.369**	**0.849 +/- 0.271**	**+0.381 (+0.340)**	**133 (66.2%)**	**W = 0.0 p < 0.001**

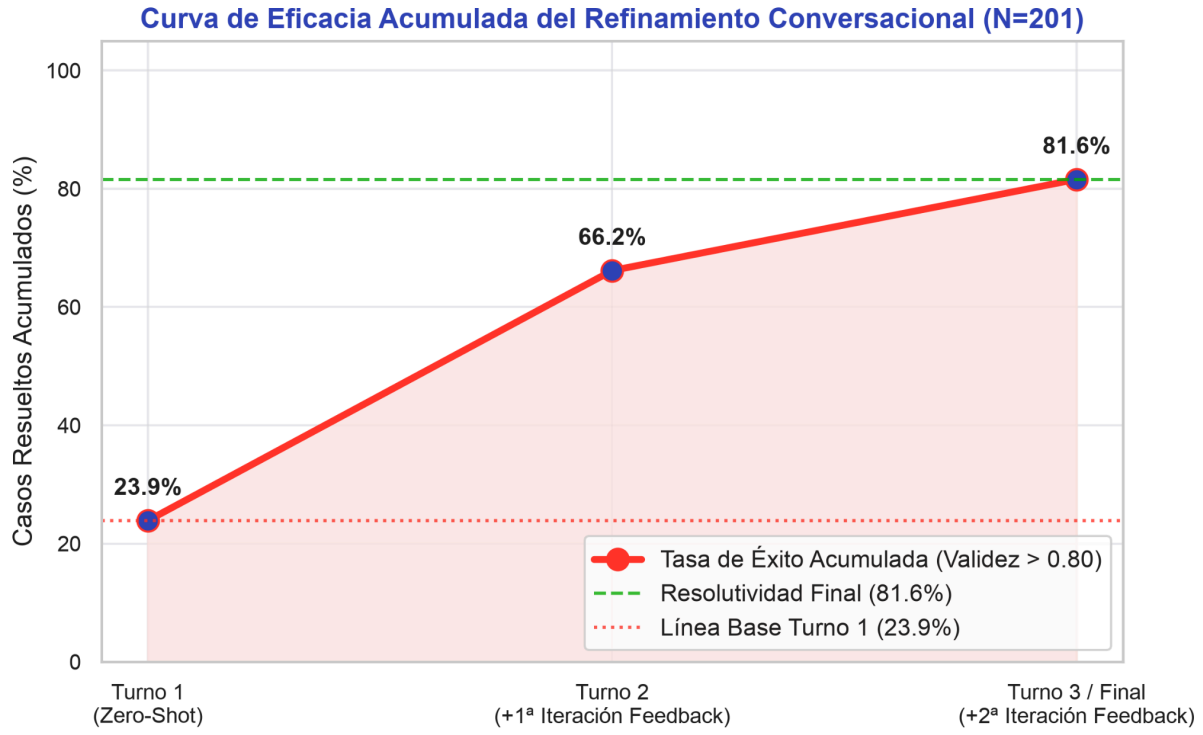


Figura 16. Curva de Eficacia Acumulada del Refinamiento Conversacional (N = 201). Evolución de la resolutividad operativa (Validez > 0.80) desde la respuesta inicial Zero-Shot hasta el tercer turno de interacción.

El paso de una interacción pura zero-shot (Turno 1) a un flujo interactivo aumentó la tasa de éxito del 23.9% (48/201) al 81.6% (164/201), lo que representa una ganancia neta absoluta de +57.7 puntos porcentuales. Confirmamos que este salto de resolutividad es estadísticamente significativo (Chi-cuadrado = 114.01, p < 0.001).

Es crucial resaltar que el valor medio de validez observado en el Turno 3 (0.579) responde a un sesgo metodológico de parada anticipada (early stopping en el 0.800) por lo que la generación de turnos se detiene al conseguir dicha puntuación: las consultas bien estructuradas abandonaron el ciclo en Turno 1 (N = 48, media 0.954) o en Turno 2 (N = 85, media 0.958). El Turno 3 aisló correctamente a las 68 consultas más complejas. Incluso dentro de este subgrupo difícil, la segunda retroalimentación mejoró de manera efectiva al

66.2% de las consultas, incrementando la mediana de 0.45 a 0.75 (prueba de Friedman 42.29, $p < 0.001$).

Discusión

El análisis por nivel de complejidad y dominios clínicos revela que la principal limitación del sistema radica en la resolución de consultas clasificadas como complejas

Mejora del Prompt

El análisis forense de los 37 casos (18.4%) que no superaron el umbral de parada operativo (> 0.80) tras el tercer turno de interacción reveló un hallazgo fundamental: las desviaciones sintácticas y semánticas observadas no respondieron a una limitación intrínseca en la capacidad de razonamiento del modelo fundacional (Gemini-2.5-Flash), sino a la ausencia de directivas precisas en el prompt de sistema (System Prompt) del Subagente Constructor de SQL

En el marco experimental evaluado, el refinamiento conversacional interactivo compensa de manera muy eficaz esta carencia a partir del Turno 2, elevando la resolutividad del sistema del 23.9% inicial hasta el 81.6% consolidado. Sin embargo, para minimizar el esfuerzo conversacional del clínico y maximizar la tasa de éxito directo en primer turno (zero-shot), se ha formalizado un conjunto de siete directrices clínico-arquitectónicas prioritarias diseñadas para su inyección directa en las instrucciones de ejecución del agente.

Mejoras a realizar en las instrucciones del agente OMOP

Selección de tablas: Eventos crudos vs. Episodios continuos (Eras): Si el requerimiento clínico solicita "episodios de tratamiento continuo", "persistencia terapéutica" o "duración de una enfermedad", el agente debe emplear obligatoriamente las tablas de agregación clínica derivadas: drug_era o condition_era. Las tablas de ocurrencia directa quedan reservadas exclusivamente para análisis de dispensaciones puntuales, vías de administración específicas, visitas o mediciones.

Expansión jerárquica y mapeos de vocabulario (concept_ancestor): Para abarcar diagnósticos agregados, subtipos o familias farmacológicas completas, el agente debe formular obligatoriamente la expansión jerárquica mediante la tabla de ancestros.

Reglas de integridad y filtrado en catálogos OMOP: En toda consulta sobre la tabla concept, a menos que se solicite un estudio histórico específico, debe fijarse como invariante la condición: `standard_concept = 'S' AND invalid_reason IS NULL`, acotando

obligatoriamente los campos domain_id (por ejemplo, 'Condition', 'Drug', 'Measurement') y vocabulary_id (por ejemplo, 'SNOMED', 'RxNorm').

Granularidad y agregación: La solicitud de "número de pacientes" o "personas" se debe traducir indefectiblemente como `COUNT(DISTINCT person_id)`, mientras que "ocurrencias", "prescripciones" o "eventos" utilicen `COUNT(*)`.

Preservación de búsquedas léxicas dinámicas: Cuando la intención del usuario sea la prospección de términos, la consulta SQL debe formularse mediante filtrado léxico dinámico: `LOWER(concept_name) LIKE '%termino%'` o `REGEXP_CONTAINS(LOWER(concept_name), r'...')`.

Estructuración modular mediante Common Table Expressions (CTEs): Toda consulta compleja o con múltiples fases de agregación temporal debe organizarse mediante una única estructura WITH, concatenando bloques CTE debidamente modularizados y con alias explícitos e intuitivos.

Beneficio e Impacto Operativo Esperado

La integración formal de estas recomendaciones en las instrucciones del sistema del agente analítico genera dos ventajas cuantitativas directas para el rendimiento del sistema:

Drástica reducción del esfuerzo conversacional (Salto en Turno 1): Al erradicar de raíz la confusión sistemática entre tablas crudas y tablas de épocas (Eras), así como la omisión involuntaria de ancestros taxonómicos, se proyecta que aproximadamente 70 de las 153 consultas que requirieron rondas iterativas de corrección en los Turnos 2 o 3 se resolvieron con éxito en el primer turno (zero-shot). Esto elevaría la resolutividad inicial del sistema desde el 23.9% actual hasta cotas estimadas por encima del 58%.

Incremento en la Validez Sintáctica Media Consolidada: Al garantizar el cumplimiento estricto del dialecto SQL de base de datos y los filtros de validez del vocabulario OMOP, la Validez Sintáctica y Estructural global del sistema experimentaría un salto cuantitativo desde el 84.9% actual hasta un rango proyectado entre el 92% y el 94%, minimizando el porcentaje de casos residuales no resueltos a menos del 8%.

En conjunto, este refinamiento basado en ingeniería de prompts contextual demuestra que la optimización guiada por los resultados experimentales permite salvar la brecha técnica del estándar OMOP CDM con una alta eficiencia, sin necesidad de reentrenar los pesos del modelo de lenguaje base ni alterar la arquitectura modular de subagentes.

Limitaciones en la evaluación de la precisión del vocabulario

Si bien la Precisión Terminológica del Vocabulario alcanzó un elevado 92.5%, es preciso señalar que el conjunto de pruebas (Gold Standard) contiene enunciados con términos clínicos relativamente directos y bien consolidados.

Esta alta precisión refleja el correcto funcionamiento de la arquitectura RAG y del subagente validador ante conceptos estándar, pero es de esperar que ante preguntas reales de mayor ambigüedad sintáctica, sinónimos poco frecuentes o descripciones clínicas imprecisas, el rendimiento terminológico se vería expuesto a un reto sensiblemente mayor.

Limitaciones detectadas para un despliegue en producción

Asumiendo que la creación de la SQL y los filtrados de los conceptos médicos fueran correctos, existen sin embargo claros retos a superar en caso de querer desplegar la solución en producción.

Diversidad de motores y dialectos de Base de Datos: Las organizaciones que utilizan OMOP CDM emplean bases de datos muy diversas (PostgreSQL, Oracle, SQLServer, Snowflake, Databricks, etc). Implicaría la creación de un subagente traductor y la disponibilidad de bases de datos para validar la SQL antes de presentarla al usuario.

Desconexión de las bases de datos reales: El flujo actual del agente asume que el clínico hace la consulta a agente OMOP (una web desconectada de la base de datos del clínico) y el agente le devuelve la SQL. A continuación, el clínico copia la SQL y la ejecuta en la base de datos de la que es usuario interrumpe el proceso natural de pregunta respuesta que espera el usuario.

Cumplimiento normativo (GDPR / PII): El clínico puede añadir por equivocación datos personales a su consulta, por lo que el sistema debería detectarlo para 1) borrar el prompt y solicitar de nuevo al clínico que rehaga la pregunta o, 2) Asumir la eliminación del dato personal antes de que la pregunta siga el proceso de solución. Este análisis debería también afectar a la SQL generada para evitar que contenga datos personales.

Conclusiones y potenciales desarrollos a futuro

Conclusiones

He validado la hipótesis principal comprobando que es viable construir un agente conversacional basado en LLM para traducir preguntas en lenguaje natural a consultas SQL

sobre el estándar OMOP CDM, reduciendo la dependencia de equipos técnicos para análisis de caracterización sencillos.

Sin embargo, resulta claro la necesidad de integrar repetidamente con el agente para que ajuste la consulta a lo que realmente queremos buscar como clínicos. Esto es solo un signo de que **si bien la generación de la SQL deja de ser un problema, la consulta mejorará enormemente en base al conocimiento y experiencia médica o clínica del usuario** que utilice el agente.

Eficacia del enfoque multi-agente con RAG, y la necesidad de crear un dataset específico para evaluar los resultados relacionados con el vocabulario: La separación de funciones entre subagentes es clave. La localización de vocabulario ha demostrado un rendimiento notable del 92.5% en validez sintáctica total, garantizando que el agente utilice los códigos estándar oficiales de la comunidad OHDSI.

Tal y como he expresado en la sección de discusión, es aquí donde generar un dataset de evaluación específico y con pruebas complejas, podría poner en serias dificultades al agente y poder extraer un detallado listado de mejoras.

Identificación de cuellos de botella: Las métricas de Validez Sintáctica total (84.9%) y de primer turno (23.9%) demuestran que, si bien el sistema ofrece respuestas en el 93.5% de los caos (Ejecución técnica real) las preguntas sencillas e intermedias, la generación automática de SQL complejas (15.4% de validez sintáctica en primer turno) normalmente no se resuelven en una primera iteración, sino que requieren siempre correcciones del prompt por parte del evaluador (o potencial clínico usuario).

Aportación a los ODS: El proyecto sienta las bases para democratizar el acceso a los datos biomédicos, contribuyendo directamente a reducir desigualdades técnicas en instituciones de salud y acelerando el análisis de datos observacionales (ODS 3, 4, 9 y 10).

Potenciales desarrollos a futuro

Como potenciales desarrollos inmediatos a corto plazo destacaría:

Mejora del prompt de sistema del agente: La incorporación de las recomendaciones enumeradas en la sección ‘Mejoras a realizar en las instrucciones del agente OMOP’.

Soporte avanzado para la jerarquía de conceptos: Incorporar reglas para que el agente inyecte automáticamente la tabla `CONCEPT_ANCESTOR` cuando la pregunta médica requiere agrupar diagnósticos o familias de fármacos.

Evolución a ADK 2.0: Migrar la arquitectura actual a la versión ADK 2.0 (Agent Development Kit) para aprovechar sus nuevas capacidades nativas en gestión de orquestación, obligando al agente a no saltarse ningún proceso de validación.

En conclusión, aunque existen desafíos en la generación de consultas complejas y en su integración técnica en entornos de producción, este proyecto demuestra que la combinación de arquitecturas multi-agente y el estándar OMOP CDM presenta una base viable y con recorrido para democratizar el análisis de datos clínicos OMOP en el ámbito sanitario.

Bibliografía

Observational Health Data Sciences and Informatics (OHDSI). (2025). *2025 Journey*. https://www.ohdsi.org/wp-content/uploads/2025/10/OurJourney-2025.pdf

Observational Health Data Sciences and Informatics (OHDSI) collaborative. (2021). *The Book of OHDSI*. OHDSI Community. https://ohdsi.github.io/TheBookOfOhdsi/

Observational Health Data Sciences and Informatics (OHDSI). (n.d.). *Data standardization: OMOP Common Data Model*. https://www.ohdsi.org/data-standardization/

Hripcsak, G. (2025, 13 de octubre). *State of the OHDSI community* [Diapositivas de presentación]. Observational Health Data Sciences and Informatics. https://www.ohdsi.org/wp-content/uploads/2025/10/OHDSI2025-Hripcsak-State-of-Communiy.pdf

SNOMED International. (n.d.). *SNOMED CT: Systematized nomenclature of medicine clinical terms*. https://www.snomed.org/

Observational Health Data Sciences and Informatics (OHDSI). (n.d.). *Achilles: SQL Server analyses* [Source code]. GitHub. https://github.com/OHDSI/Achilles/tree/main/inst/sql/sql_server/analyses

Observational Health Data Sciences and Informatics (OHDSI). (n.d.). *QueryLibrary: OMOP CDM queries* [Source code]. GitHub. https://github.com/OHDSI/QueryLibrary/tree/master/inst/shinyApps/QueryLibrary/queries

Observational Health Data Sciences and Informatics (OHDSI). (n.d.). *Athena: OHDSI vocabularies search*. https://athena.ohdsi.org/search-terms/terms

Google. (n.d.). *Agent Development Kit (ADK) documentation*. Google Developers. https://adk.dev/

Anexos

GIthub: https://github.com/sogire/tfm-ue-bioinformatica2526-agente-omop (y anexos)

Anexo A: Video demostrativo del agente en funcionamiento. (Link a Vídeo Online)
Anexo B: Prompts de sistema del agente.
Anexo C: Listado de preguntas a evaluar y evaluación individual.
Anexo D: Resultados agregados evaluación cuantitativa.